WIFF1.0

머신러닝 기반 파랑 유도 해빙 파단 모수화

파트별 쉬운 설명 및 프로젝트 연결

Horvat and Roach (2022)

WIFF1.0: a hybrid machine-learning-based parameterization of wave-induced sea ice floe fracture

STATS 750: Data-Driven Parameterization of Wave–Ice Interactions in the Great Lakes

정리: Donghyun Kim

Contents

1 논문 전체를 한 문장으로 요약하면 **1**

2 이전 논문들과 이 논문의 관계 **1**

3 먼저 구분해야 할 네 가지 분포 **2**

4 Section 1 — Introduction **3**

4.1 왜 FSD가 필요한가? . . . 3

4.2 파단은 농도와 두께를 즉시 바꾸지 않는다 . . . 3

4.3 파랑–얼음 피드백 . . . 4

4.4 왜 단순 power-law FSD를 사용하지 않는가? . . . 5

4.5 파랑 스펙트럼과 유의파고 . . . 5

4.6 SP-WIFF의 두 가지 문제 . . . 6

4.6.1 계산비용 . . . 6

4.6.2 bitwise reproducibility 부족 . . . 6

5 Section 2 — SP-WIFF 물리모형 **6**

5.1 식 (1): 방향 스펙트럼을 1차원 스펙트럼으로 변환 . . . 7

5.2 식 (2): FSD가 파단으로 어떻게 변하는가? . . . 7

5.2.1 첫 번째 항: 크기 r floe의 손실 . . . 7

5.2.2 두 번째 항: 더 큰 floe에서 들어오는 유입 . . . 7

5.2.3 τ: 파단을 적용하는 시간척도 . . . 8

6 SP-WIFF의 S1–S3 과정 **8**

6.1 S1. 스펙트럼으로부터 무작위 얼음 변형률장 생성 . . . 9

6.2 S2. 파단 길이 $\{L\}$ 계산 . . . 9

6.3 S3. 히스토그램이 수렴할 때까지 반복 . . . 9

7 식 (3)과 (4): $A(r)$를 실제 FSD 변화에 연결 **9**

7.1 식 (3): 크기 r floe가 파단될 확률 . . . 9

7.2 식 (4): 깨진 후 조각 크기의 조건부 분포 . . . 10

7.3 신경망이 실제로 대체하는 위치 . . . 10

8 Section 3 — NN-WIFF 학습자료 구성 **11**

8.1 자료는 어디서 왔는가? . . . 11

8.2 사전 필터링 조건 . . . 12

8.3 정확한 입력과 출력 . . . 12

8.3.1 입력: 총 27개 . . . 12

8.3.2 출력: 12개 파단 크기구간 . . . 13

8.4 왜 신경망을 두 개로 나누었는가? . . . 13

9 두 신경망의 구조 **14**

10 Section 3.1 — 파단 분류기 **14**

10.1 분류기 자료분할 . . . 14

10.2 분류 오차 . . . 15

10.2.1 False positive의 물리적 의미 . . . 15

10.2.2 False negative의 물리적 의미 . . . 15

10.3 Figure 1 해석 . . . 16

10.3.1 위쪽 (a)–(c): 변수별 분류성능 . . . 16

10.3.2 아래쪽 (d)–(f): 두 변수 조합에 따른 정확도 . . . 17

10.4 논문의 해석과 주의점 . . . 17

11 Section 3.2 — 파단 히스토그램 신경망 **18**

11.1 Softmax를 사용하는 이유 . . . 18

11.2 식 (6): Representative Size Error . . . 18

11.3 식 (7): 평균 학습성능 . . . 19

11.4 식 (8): Representative radius . . . 19

11.5 식 (9): Standardized Size Error . . . 19

12 Figure 2 — 히스토그램 신경망의 전체 성능 **20**

12.1 (a) 해빙농도 . . . 20

12.2 (b) 해빙두께 . . . 20

12.3 (c) 파랑에너지 . . . 20

12.4 (d) 실제 representative radius R . . . 21

12.5 (e) 실제·예측 평균 히스토그램 . . . 21

13 Figure 3 — 어느 조건에서 오차가 커지는가? 21

14 Section 4 — CICE 안에서의 실제 검증 23

14.1 검증 설정 . . . 23

14.2 호출 횟수 차이 . . . 23

15 Figure 4 — CICE 내부에서의 파단분포 오차 24

15.1 위쪽 (a), (b): 평균 파단 히스토그램 . . . 24

15.2 아래쪽 (c), (d): SP-WIFF 대비 오차분포 . . . 24

15.3 중요한 조건부 비교 문제 . . . 25

16 Figure 5 — 모형 전체 해빙 상태에 미친 영향 26

16.1 첫 번째 행: 해빙농도 차이 . . . 26

16.2 두 번째 행: 단위면적당 해빙부피 차이 . . . 26

16.3 세 번째 행: 평균 floe 크기 비율 . . . 27

16.4 “통계적으로 동일하다”의 정확한 의미 . . . 27

17 계산시간 결과 28

18 Section 5 — 결론과 한계 29

18.1 논문의 최종 성과 . . . 29

18.2 왜 offline 3.9%가 모델 내부에서 8.4%가 되었는가? . . . 29

18.3 단일 연도·단일 모형 자료의 문제 . . . 29

18.4 논문이 제안한 가장 좋은 향후 구조 . . . 30

18.5 물리모형 자체의 가정 . . . 31

19 Great Lakes 프로젝트에 직접 적용하면 31

19.1 그대로 가져올 수 있는 것 . . . 31

19.1.1 1. Teacher–surrogate 연구구조 . . . 31

19.1.2 2. 두 단계 fracture 구조 . . . 31

19.1.3 3. 물리제약을 적용한 출력 . . . 32

19.1.4 4. 전체 모델 안에서의 검증 . . . 32

19.1.5 5. OOD fallback . . . 32

19.2 Great Lakes에 그대로 가져오면 안 되는 것 . . . 32

20 네 프로젝트에서는 논문보다 개선하면 좋은 부분 **33**

20.1 무작위 70/30 분할 대신 blocked split 33

20.2 평균오차 외에 물리적 결과 평가 33

20.3 불확실성 제시 33

21 이 논문에서 반드시 집중해서 읽을 부분 **34**

22 최종 요약 **34**

1. 논문 전체를 한 문장으로 요약하면

분석 대상은 Horvat and Roach (2022), *WIFF1.0: a hybrid machine-learning-based parameterization of wave-induced sea ice floe fracture*이다.

> 계산비용이 매우 큰 물리 기반 파단모형 SP-WIFF가 만드는 결과를 학습시켜, 같은 역할을 훨씬 빠르고 재현 가능하게 수행하는 신경망 대리모형 NN-WIFF를 만든 논문이다.

중요한 점은 이 논문이 다음을 하는 것이 아니라는 것이다.

- 관측자료만으로 새로운 wave–ice 물리를 발견한 연구가 아니다.
- 파랑감쇠계수 α를 직접 예측하는 모델이 아니다.
- WAVEWATCH III나 CICE 전체를 신경망으로 교체한 것이 아니다.
- 완전히 새로운 ice fracture 이론을 제안한 것도 아니다.

대신 다음 계산을 대체한다.

$$\boxed{\text{국소 파랑 스펙트럼} \longrightarrow \text{무작위 파면 생성} \longrightarrow \text{얼음 변형률 계산} \longrightarrow \text{파단 길이분포}}$$

기존 SP-WIFF는 이 과정을 매번 반복하지만, NN-WIFF는 그 입출력 관계를 미리 학습한다.

$$\boxed{[S_1, \ldots, S_{25}, H, C] \longrightarrow \begin{cases} \text{파단 여부,} \\ \text{파단 후 12개 크기구간의 확률분포} \end{cases}}$$

2. 이전 논문들과 이 논문의 관계

지금까지 읽은 논문들을 하나의 흐름으로 배열하면 다음과 같다.

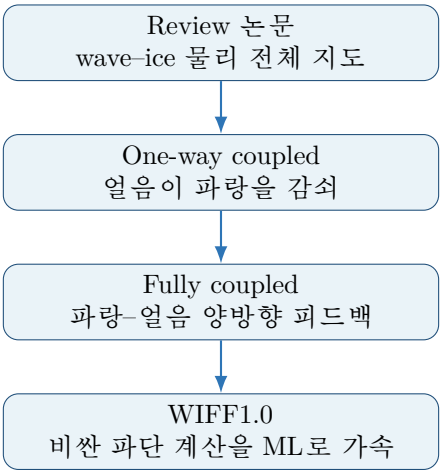


그림 1: 지금까지 읽은 논문들과 WIFF1.0의 관계

기존 one-way 논문에서 중요했던 식은 대략 다음이었다.

$$S_{\text{ice}} = -\alpha E C_g$$

여기서 α는 얼음 속 파랑감쇠계수였다. 즉,

$$\text{ice state} \longrightarrow \alpha \longrightarrow \text{wave attenuation}$$

을 다뤘다.

반면 이번 논문은 감쇠 후 남아 있는 파랑 스펙트럼이 얼음을 어떻게 부수는지를 다룬다.

$$\text{wave spectrum} \longrightarrow \text{ice strain} \longrightarrow \text{fracture} \longrightarrow \text{FSD 변화}$$

이를 fully coupled 구조에 넣으면 전체 연결은 다음과 같다.

$$f(r,t) \longrightarrow \alpha(\lambda, f) \longrightarrow S(\lambda, t) \longrightarrow A(r) \longrightarrow \frac{\partial f}{\partial t}$$

- $f(r,t)$: 현재 floe size distribution, FSD
- α: 얼음에 의한 파랑감쇠
- $S(\lambda, t)$: 감쇠된 파랑 스펙트럼
- $A(r)$: 파랑에 의해 만들어질 파단 길이분포
- $\partial f/\partial t$: 파단으로 인한 FSD 변화

따라서 이번 논문은 위 연쇄 중에서

$$\boxed{S(\lambda), H, C \longrightarrow A(r)}$$

부분을 신경망으로 대체한다.

3. 먼저 구분해야 할 네 가지 분포

이 논문은 여러 종류의 "분포"를 사용하기 때문에 기호를 먼저 구분해야 한다.

기호	의미	적분 또는 합
$S(\lambda)$	파장별 파랑에너지 스펙트럼	$\int S(\lambda)d\lambda = E$
$f(r,t)$	현재 모델 격자 안의 FSD	$\int f(r,t)dr = C$
$A(r)dr$	SP-WIFF가 계산한 파단 길이 히스토그램	파단 발생 시 $\int A(r)dr = 1$
$F(r,s)ds$	크기 r인 부모 floe가 파단되어 크기 s가 될 조건부 분포	$\int_0^r F(r,s)ds = 1$

여기서 $f(r,t)$와 $A(r)$를 혼동하면 안 된다.

- $f(r,t)$: 현재 실제로 존재하는 얼음 조각들의 분포
- $A(r)$: 지금 주어진 파랑이 얼음을 부순다면 만들어낼 파단 길이의 분포

NN-WIFF의 직접 출력은 $f(r,t)$가 아니라 $A(r)$이다. 이후 $A(r)$를 사용해 $\Omega(r,t)$와 $F(r,s,t)$를 만들고, 그것을 FSD 진화식에 넣어 $f(r,t)$를 변경한다. $\Omega(r,t)$: 크기 r인 floe가 깨질 확률 / $F(r,s,t)$: 크기r인 floe가 깨졌을 때 s 크기 조각이 생길 확률

$$\Omega(r,t) = \int_0^r A(s,t)\,ds$$

$$F(r,s,t) = \begin{cases} \dfrac{A(s,t)}{\Omega(r,t)}, & s \le r, \\ 0, & s > r \end{cases}$$

4. Section 1 — Introduction

4.1. 왜 FSD가 필요한가?

실제 해빙은 하나의 연속된 판이 아니라 크기가 서로 다른 floe들의 집합이다.

- 작은 floe: 수 m
- 큰 floe: 수 km 또는 수십 km
- 그 사이에 다양한 크기의 조각 존재

그러나 기후모형의 격자 하나는 수십 km 이상일 수 있기 때문에 각 floe를 직접 해상할 수 없다. 그래서 격자 내부의 floe 크기를 확률분포로 나타낸다.

$$f(r)dr = \text{크기가 } r \sim r+dr \text{인 floe가 차지하는 격자 면적 비율}$$

따라서

$$\int_0^\infty f(r)dr = C$$

이고 C는 해빙농도이다.

예를 들어 어떤 격자의 해빙농도가 $C = 0.8$이라면 전체 격자의 80%가 얼음이고, 그 80%가 여러 floe 크기구간에 분배되어 있다는 뜻이다.

4.2. 파단은 농도와 두께를 즉시 바꾸지 않는다

논문에서 강조하는 중요한 물리적 해석이다.

파랑이 큰 floe를 여러 개의 작은 floe로 부순다고 해보자.

$$\text{큰 floe 1개} \longrightarrow \text{작은 floe 여러 개}$$

이 순간에는

- 총 얼음 면적이 없어지지 않고
- 얼음 부피도 거의 그대로이며
- 평균 두께도 직접 바뀌지 않는다.

대신 floe 둘레가 크게 증가한다.

$$\text{동일한 면적} \quad + \quad \text{훨씬 긴 전체 둘레}$$

그러면 이후에

- 측면 융해가 증가하고
- 바람과 해류에 대한 운동 반응이 달라지고
- floe 간 충돌 및 이동 특성이 달라지고
- 파랑감쇠 특성도 변할 수 있다.

즉, 파단의 효과는 즉각적인 농도 감소가 아니라 후속 열역학·역학 과정의 변화로 나타난다.

4.3. 파랑–얼음 피드백

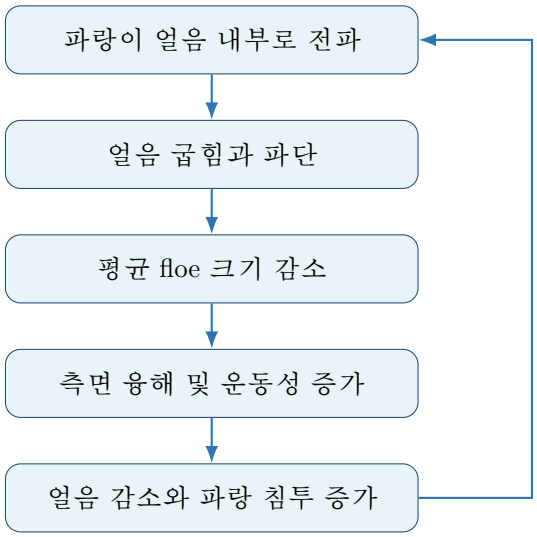


그림 2: 파랑–얼음 피드백의 개념도

이것이 fully coupled 논문에서 보았던 핵심 피드백이다.

하지만 대규모 기후모형 안에서 이 모든 파단 과정을 직접 계산하기에는 너무 비싸다. 그래서 sub-grid parameterization이 필요하다.

4.4. 왜 단순 power-law FSD를 사용하지 않는가?

기존 모형들은 파단된 floe 크기가 대략 power law를 따른다고 가정하는 경우가 많았다.

$$p(r) \propto r^{-\gamma}$$

문제는 다음과 같다.

- 실제 관측 FSD가 항상 power law인지 불분명하다.
- wave-induced fracture가 실제로 power law를 생성하는지도 확실하지 않다.
- 동일한 에너지라도 파랑의 주기별 구성과 위상에 따라 파단 결과가 달라질 수 있다.

따라서 이 논문은 미리 정해진 power law를 적용하기보다는, 물리모형 SP-WIFF가 계산한 파단분포를 신경망으로 근사한다.

4.5. 파랑 스펙트럼과 유의파고

논문에서는

$$E = \int S(\lambda) d\lambda$$

로 스펙트럼 전체 에너지를 정의한다. 여기서 E는 실제 단위가 joule인 총에너지라기보다 파면 높이의 분산에 해당하는 spectral energy이며 단위는 m^2이다.

표준 관계는

$$\boxed{H_s = 4\sqrt{E}}$$

이다.

예를 들어

$$E = 0.01\ \mathrm{m}^2 \quad \Rightarrow \quad H_s = 4\sqrt{0.01} = 0.4\ \mathrm{m}$$

이다.

참고로 논문 서론에는 $E = 4\sqrt{H_s}$처럼 보이는 조판이 있지만, 차원이 맞지 않는다. 논문 3절에서 실제로 사용하는 관계와 표준 정의는 $H_s = 4\sqrt{E}$이다.

4.6. SP-WIFF의 두 가지 문제

기존 SP-WIFF는 매 격자·시간 단계마다 무작위 위상을 생성하고 물리적 파단을 반복 계산한다.

그 결과 다음 문제가 생긴다.

4.6.1. 계산비용

CICE에 SP-WIFF를 넣으면 계산시간이 크게 증가한다. 기후모형을 수십 년 또는 수백 년 적분할 경우 현실적으로 부담이 크다.

4.6.2. bitwise reproducibility 부족

같은 초기조건과 forcing을 넣더라도 매번 다른 무작위 파면이 생성된다. 따라서 두 실행의 결과가 기계 정밀도 수준에서 완전히 같지 않다.

기후모형 개발에서는 코드 수정 전후에 결과가 정확히 같은지를 확인하는 테스트가 중요하므로 이 특성은 불편하다.

프로젝트 연결

이 서론에서 네 프로젝트가 가져가야 할 가장 중요한 관점은 다음이다.

> ML의 목적은 physics를 없애는 것이 아니라, 충분히 신뢰할 수 있지만 너무 비싼 numerical parameterization을 빠르게 근사하는 것이다.

네 프로젝트의 기본 구조도 다음과 같이 잡는 것이 가장 자연스럽다.

$$X \xrightarrow{\text{기존 물리모형}} Y_{\text{physics}}$$

로 입출력 자료를 만든 후,

$$\hat{Y}_{\text{ML}} = g_\theta(X)$$

를 학습시키고

$$\hat{Y}_{\text{ML}} \approx Y_{\text{physics}}$$

인지 확인하는 것이다.
다만 이것은 "자연을 정확히 재현했다"가 아니라 "기존 물리모형을 잘 흉내 냈다"는 뜻이다.
관측자료와의 물리적 타당성 검증은 별도의 문제다.

5. Section 2 — SP-WIFF 물리모형

이 절은 논문에서 가장 중요하다. 신경망이 무엇을 대체하는지를 이해하려면 먼저 SP-WIFF가 계산하는 내용을 알아야 한다.

5.1. 식 (1): 방향 스펙트럼을 1차원 스펙트럼으로 변환

원래 파랑은 파장과 방향을 모두 갖는다.

$$S(\lambda_i, \Theta)$$

- λ_i: i 번째 파장
- Θ: 파랑 진행방향

논문에서는 방향에 대해 적분해 1차원 스펙트럼을 만든다.

$$\boxed{S(\lambda_i)d\lambda_i = \int_0^{2\pi} S(\lambda_i, \Theta)d\lambda_i \, d\Theta} \tag{1}$$

즉, 방향 정보를 모두 합쳐 "파장별로 에너지가 얼마나 있는가"만 남긴다.

이 논문의 NN 입력도 최종적으로 이 파장별 스펙트럼을 25개의 구간으로 이산화한 값이다.

5.2. 식 (2): FSD가 파단으로 어떻게 변하는가?

$$\boxed{\frac{\partial f(r,t)}{\partial t} = \frac{1}{\tau}\left[-f(r,t)\Omega(r,t) + \int_r^{\infty} \Omega(s,t)f(s,t)F(s,r,t)ds\right]} \tag{2}$$

복잡해 보이지만 구조는 일반적인 "손실–유입" 식이다.

$$\boxed{\text{크기 } r \text{ floe 변화} = \text{유입} - \text{손실}}$$

5.2.1. 첫 번째 항: 크기 r floe의 손실

$$-f(r,t)\Omega(r,t)$$

- 현재 크기 r 인 floe의 양: $f(r,t)$
- 그중 파랑에 의해 깨질 비율: $\Omega(r,t)$

따라서 이 항은 크기 r 구간에서 사라지는 면적을 의미한다.

5.2.2. 두 번째 항: 더 큰 floe에서 들어오는 유입

$$\int_r^{\infty} \Omega(s,t)f(s,t)F(s,r,t)ds$$

크기 $s > r$ 인 큰 floe가 깨지면서 크기 r 인 작은 floe를 만들 수 있다. 모든 $s \geq r$ 에 대해 그 양을 더한 것이 이 적분이다.

예를 들어 100 m floe가 깨져 30 m와 70 m floe를 만든다면

- 100 m 구간에서는 손실
- 30 m와 70 m 구간에서는 유입

이 발생한다.

적분 하한이 r인 이유는 작은 floe가 깨져 더 큰 floe가 될 수 없기 때문이다.

$$F(s, r) = 0 \qquad (s < r)$$

5.2.3. τ: 파단을 적용하는 시간척도

$$\frac{1}{\tau}$$

는 파단 변화가 얼마나 빠르게 적용되는지를 결정한다. 실제 구현에서는 빠른 파랑과 작은 FSD 구간에서도 수치적으로 안정하도록 adaptive time stepping으로 정한다.

식 (2)는 FSD 전체 진화식 중 파단에 해당하는 한 항이다. 실제 CICE에서는 여기에

- 융해와 성장
- 이류
- 역학적 재분배
- 기타 열역학 과정

등이 함께 들어간다.

6. SP-WIFF의 S1–S3 과정

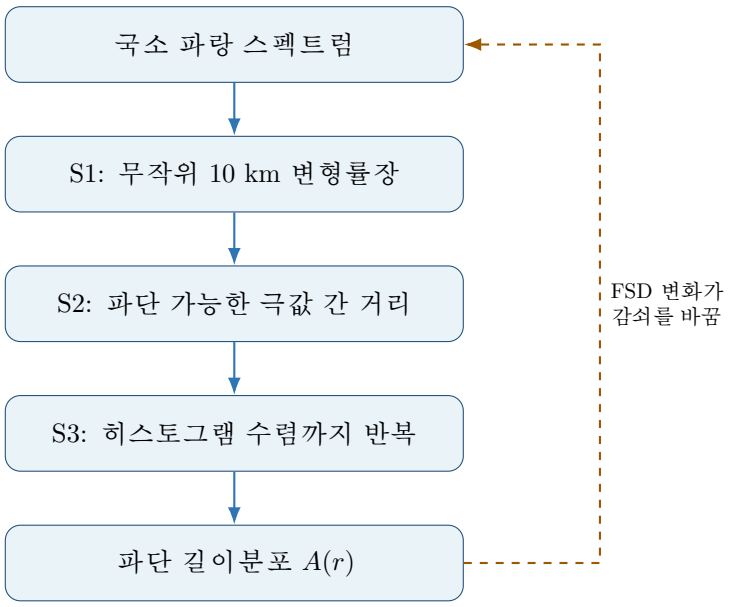


그림 3: SP-WIFF의 확률적 파단 계산 과정

6.1. S1. 스펙트럼으로부터 무작위 얼음 변형률장 생성

주어진 $S(\lambda)$ 만으로는 실제 파면 모양이 하나로 결정되지 않는다. 각 파랑 성분의 위상 ϕ_i 가 달라질 수 있기 때문이다.

개념적으로는 다음과 같다.

$$S(\lambda) + \{\phi_i\} \longrightarrow \eta(x)$$

여기서 $\eta(x)$ 는 길이 10 km의 1차원 얼음 변형률장이다.

같은 스펙트럼이라도 무작위 위상이 달라지면 높은 굽힘이 나타나는 위치와 크기가 달라지고, 그에 따라 파단 위치도 달라진다.

6.2. S2. 파단 길이 $\{L\}$ 계산

얼음이 임계 변형률을 초과하여 깨질 수 있는 연속된 극값 사이의 거리를 찾는다.

$$\{L_1, L_2, \ldots, L_n\}$$

이 길이들을 구간별로 모아 파단 길이 히스토그램 $A(r)$ 을 만든다.

$$A(r)dr = \text{파단 길이가 } r \sim r + dr \text{에 속하는 길이 가중 비율}$$

6.3. S3. 히스토그램이 수렴할 때까지 반복

S1에서 위상을 무작위로 선택했기 때문에 한 번의 계산만으로는 안정적인 통계량을 얻기 어렵다.

따라서 S1과 S2를 반복하고, 연속된 두 $A(r)$ 의 평균절대차이가

$$5 \times 10^{-4}$$

보다 작아질 때까지 계속한다.

이 반복 때문에 SP-WIFF는 느리고, 반복 횟수도 사전에 알 수 없다.

7. 식 (3)과 (4): $A(r)$ 를 실제 FSD 변화에 연결

7.1. 식 (3): 크기 r floe가 파단될 확률

$$\boxed{\Omega(r,t) = \int_0^r A(s,t)ds} \tag{3}$$

이는 파단 길이가 현재 floe 크기 r 보다 작을 확률이다.

직관적으로 보면 다음과 같다.

- 파단 특성길이 20 m
- 현재 floe 크기 100 m

라면 100 m floe 내부에 파단이 발생할 수 있다.

반대로

- 파단 특성길이 200 m
- 현재 floe 크기 100 m

라면 floe보다 파단 길이가 더 크므로 그 floe를 나눌 수 없다.

따라서 $A(s)$를 0부터 r까지 누적한 값이 크기 r floe가 깨질 비율이 된다.

7.2. 식 (4): 깨진 후 조각 크기의 조건부 분포

$$\boxed{F(r,s,t)ds = \begin{cases} \dfrac{A(s,t)ds}{\displaystyle\int_0^r A(l,t)dl} = \dfrac{A(s,t)ds}{\Omega(r,t)}, & s \le r, \\ 0, & s > r \end{cases}} \tag{4}$$

여기서

- r: 깨지기 전 부모 floe 크기
- s: 깨진 후 만들어지는 자식 floe 크기

이다.

분모의 $\Omega(r,t)$는 $s \le r$ 범위에서 확률의 합이 1이 되도록 정규화한다.

$$\int_0^r F(r,s,t)ds = 1$$

7.3. 신경망이 실제로 대체하는 위치

SP-WIFF는 S1–S3을 통해 $A(r)$를 만들고, 식 (3)과 (4)를 통해 Ω와 F를 계산한다.

NN-WIFF는 다음만 대체한다.

$$\boxed{\text{S1–S3} \quad \Rightarrow \quad \hat{A}(r)}$$

식 (2)–(4)로 FSD를 갱신하는 물리적 구조는 그대로 남는다.

이것이 "hybrid ML parameterization"이라고 부를 수 있는 이유다.

프로젝트 연결

네 프로젝트에서 "무엇을 ML로 대체할 것인가"를 이 정도로 명확하게 정의해야 한다.

후보 ML target	대체하는 물리과정
$\hat{\alpha}(f)$	주파수별 파랑감쇠 계산
$\hat{S}_{\text{ice}}(f)$	감쇠 source term 계산
$P(\text{fracture} \mid X)$	파단 발생 판단
$\hat{A}(r)$	파단 길이분포 계산
$\hat{f}(r, t + \Delta t)$	FSD 전체 업데이트

이번 논문이 직접 다루는 것은 세 번째와 네 번째다.

$$P(\text{fracture} \mid X) \quad + \quad \hat{A}(r) \mid \text{fracture}$$

따라서 이 논문을 근거로 "ML을 적용한다"고 쓸 때는 단순히 "wave–ice interactions를 예측한다"고 쓰기보다

> "expensive한 stochastic wave-induced fracture subroutine을 분류기와 조건부 분포 신경망으로 근사한다"

고 구체적으로 쓰는 것이 좋다.

8. Section 3 — NN-WIFF 학습자료 구성

8.1. 자료는 어디서 왔는가?

학습자료는 2009년 CICE–WAVEWATCH III coupled simulation에서 추출했다.

6시간마다 다음 값을 수집했다.

- 파랑 스펙트럼
- 해빙농도
- 평균 해빙두께
- SP-WIFF가 계산한 파단 히스토그램

전체 가능한 입력은 약 1억 8천만 개였지만 대부분 얼음이 없는 격자였다.

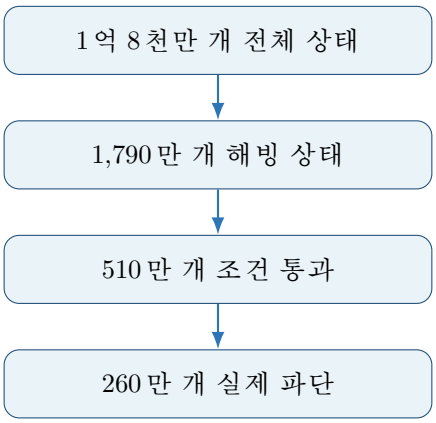


그림 4: NN-WIFF 학습자료의 단계별 필터링

8.2. 사전 필터링 조건

다음 조건을 모두 만족할 때만 WIFF 계산 대상으로 사용했다.

$$H < 10\,\mathrm{m}$$

$$C > 0.01$$

$$H_s > 0.1\,\mathrm{m}$$

즉,

- 비정상적으로 두꺼운 얼음 제외
- 얼음이 거의 없는 격자 제외
- 파랑에너지가 너무 작은 격자 제외

이다.

$H_s = 4\sqrt{E}$를 적용하면 $H_s > 0.1\,\mathrm{m}$는

$$E > \left(\frac{0.1}{4}\right)^2 = 6.25 \times 10^{-4}\,\mathrm{m}^2$$

에 해당한다.

8.3. 정확한 입력과 출력

8.3.1. 입력: 총 27개

$$X = [S_1, S_2, \ldots, S_{25}, H, C]$$

- 25개 파랑 스펙트럼 진폭
- 해빙두께 H
- 해빙농도 C

8.3.2. 출력: 12개 파단 크기구간

$$Y = [A_1 dr_1, \ldots, A_{12} dr_{12}]$$

파단이 일어나면

$$\sum_{i=1}^{12} A_i dr_i = 1$$

이 된다.

여기서 현재 평균 floe 크기는 신경망의 직접 입력에 포함되지 않는다. 평균 floe 크기는 wave model에서 감쇠를 계산해 국소 파랑 스펙트럼을 만드는 데 영향을 주므로, 결과적으로 25개 스펙트럼 값에 간접적으로 반영된다.

8.4. 왜 신경망을 두 개로 나누었는가?

SP-WIFF를 실행해도 항상 파단되는 것은 아니다.

따라서 출력은 다음과 같은 zero-inflated 구조다.

$$Y = \begin{cases} \mathbf{0}, & \text{파단 없음}, \\ A(r), & \text{파단 있음} \end{cases}$$

하지만 softmax는 항상 합이 1인 분포를 만든다. 파단이 없을 때 필요한 영벡터

$$[0, \ldots, 0]$$

를 만들 수 없다.

그래서 논문은 hurdle model과 유사한 2단계 구조를 사용한다.

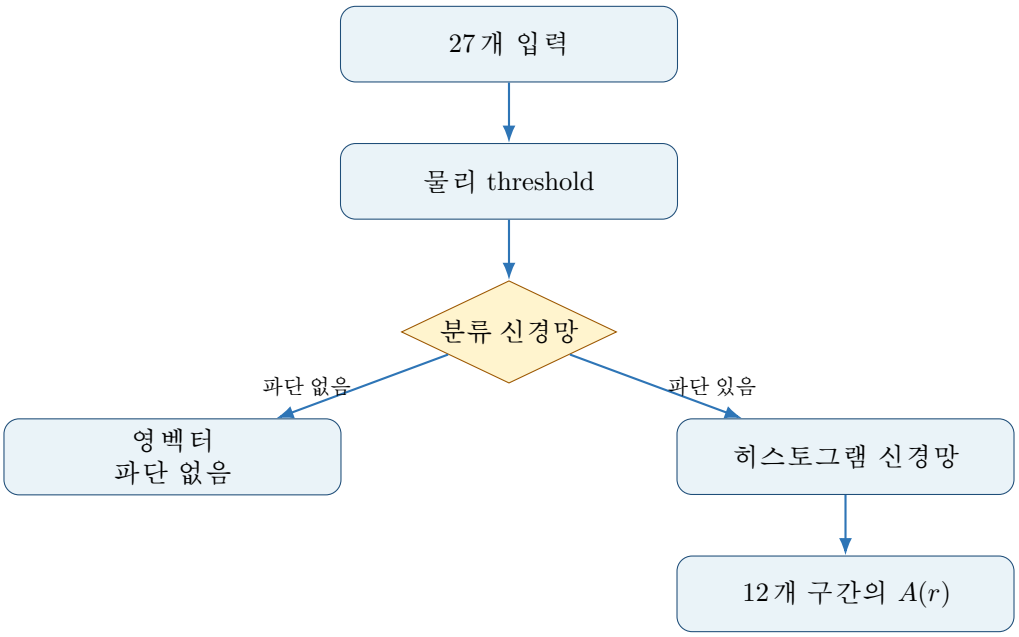


그림 5: NN-WIFF의 두 단계 파단 예측 구조

9. 두 신경망의 구조

항목	파단 분류기	히스토그램 생성기
목적	파단 여부 판단	파단 시 $A(r)$ 예측
입력	27개	27개
은닉층	약 100×100 구조	100개 노드의 은닉층 5개
은닉 활성화	ReLU	ReLU
최종 활성화	Softmax 기반 분류점수	Softmax
자료	510만 개 전체 입력	약 260만 개 파단 사례
출력	파단/비파단	12개 확률구간

학습에는 Keras와 Adam을 사용했다. 구조는 층 수, 노드 수, 손실함수 등을 바꿔 선택했는데, 논문이 "meta-learning"이라고 부르는 것은 현대적인 MAML 방식이라기보다 실질적으로 architecture/hyperparameter search에 가깝다.

히스토그램 신경망은 validation loss가 20번 연속 개선되지 않으면 학습을 중단했다.

10. Section 3.1 — 파단 분류기

10.1. 분류기 자료분할

510만 개 입력을 무작위로 나눈다.

- 학습 70%: 약 360만 개

- 검증 30%: 약 150만 개
- 약 51%가 실제 파단 사례

분류기는 $0 < \chi < 1$인 점수를 출력한다. 논문의 점수 정의에서는

$$\chi < \chi_{\text{crit}}$$

이면 히스토그램 신경망을 실행한다.

10.2. 분류 오차

총 오차율은

$$\boxed{\epsilon = \frac{\text{false positives} + \text{false negatives}}{\text{전체 입력 수}}} \tag{5}$$

이다.

검증자료에서 최적 임곗값은

$$\chi_{\text{crit}} = 0.54$$

였으며 결과는 다음과 같다.

지표	결과
전체 분류오차 ϵ	12.5%
정확도	87.5%
False positive rate	10.6%
False negative rate	14.0%

10.2.1. False positive의 물리적 의미

실제 SP-WIFF는 파단하지 않는다고 했지만 NN-WIFF가 파단시킨 경우다.

$$\text{실제 비파단} \longrightarrow \text{NN은 파단}$$

결과적으로 큰 floe가 잘못 작아질 수 있다.

10.2.2. False negative의 물리적 의미

실제 SP-WIFF는 파단한다고 했지만 NN-WIFF가 파단하지 않은 경우다.

실제 파단 ⟶ NN은 비파단

결과적으로 큰 floe가 그대로 남고 MIZ 경계 위치가 달라질 수 있다.

10.3. Figure 1 해석

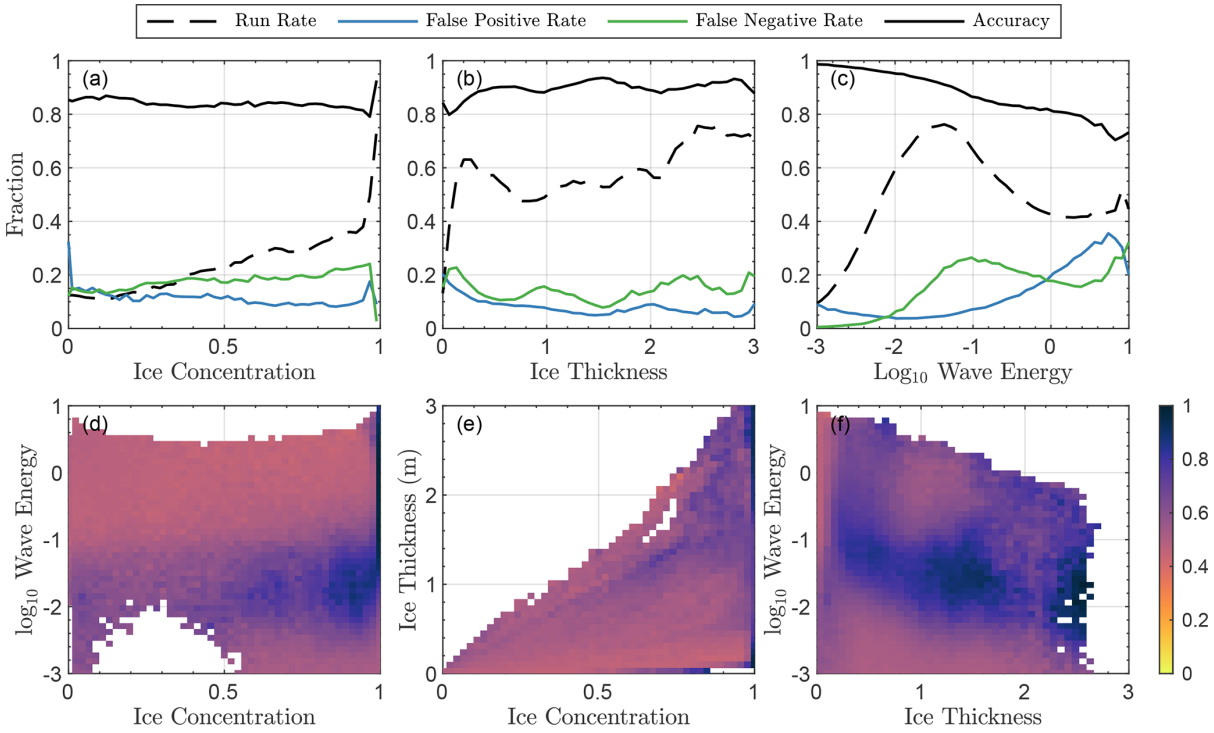


그림 6: NN-WIFF 입력 분류기의 성능. 원논문 Figure 1.

10.3.1. 위쪽 (a)–(c): 변수별 분류성능

- 검은 실선: 정확도
- 검은 점선: 분류기가 파단 히스토그램 신경망을 실행하는 비율
- 파란색: false positive
- 녹색: false negative

(a) 해빙농도. 대부분의 농도 범위에서 정확도가 약 80–90%로 비교적 일정하다. 농도가 높아질수록 NN-WIFF 실행 비율이 증가한다.

(b) 해빙두께. 두께에 대해서도 정확도가 비교적 안정적이다. 대략 0.5–2.5 m 구간에서 특히 높다.

(c) 파랑에너지. 파랑에너지가 커질수록 정확도가 감소하는 경향이 나타난다.

실행률은 대략

$$E = 0.01 \sim 0.1\ \mathrm{m}^2$$

에서 가장 높다. 이는

$$H_s = 4\sqrt{E}$$

에 따라 대략 $H_s = 0.4 \sim 1.26$ m이고, 논문은 대표적으로 약 70 cm 부근의 파랑을 언급한다.

매우 높은 파랑에너지에서는 false positive와 false negative가 모두 20%를 넘는다.

10.3.2. 아래쪽 (d)–(f): 두 변수 조합에 따른 정확도

- (d): 해빙농도–파랑에너지
- (e): 해빙농도–두께
- (f): 두께–파랑에너지

일부 희소한 영역에서는 정확도가 42%까지 떨어진다. 하지만 학습자료가 많이 존재하고 실제 실행률이 높은 영역에서는 정확도가 높다.

10.4. 논문의 해석과 주의점

논문은 전체 분류정확도 87.5%가 최종 기후모형 결과에 통계적으로 큰 차이를 만들지 않는다고 주장한다.

그러나 분류문제에서는 전체 정확도만으로 충분하지 않다.

특히 프로젝트에서는 다음을 구분해야 한다.

- 파단을 놓치는 것이 더 위험한가?
- 파단을 잘못 발생시키는 것이 더 위험한가?
- 두 오차가 downstream H_s, FSD, ice edge에 미치는 비용이 같은가?

예를 들어 false negative가 MIZ 경계를 체계적으로 좁게 만들 수 있다면 다음과 같은 가중손실을 고려할 수 있다.

$$L_{\mathrm{class}} = w_{\mathrm{FN}} L_{\mathrm{FN}} + w_{\mathrm{FP}} L_{\mathrm{FP}}$$

여기서 $w_{\mathrm{FN}} > w_{\mathrm{FP}}$로 설정할 수 있다.

프로젝트 연결

Great Lakes 자료에서도 파단 사례가 드물거나 특정 storm에 집중된다면 단일 회귀모형보다 다음 구조가 적합할 수 있다.

$$\hat{p}(X) = P(\text{fracture} \mid X)$$

$$\hat{A}(r \mid X, \text{fracture})$$

다만 논문의 $H_s > 0.1\,\text{m}$, $C > 0.01$, $H < 10\,\text{m}$ 임곗값을 그대로 복사해서는 안 된다. 이것은 CICE의 해빙 환경을 기준으로 정한 값이므로 Great Lakes 자료의 분포와 물리모형에 맞게 다시 결정해야 한다.

11. Section 3.2 — 파단 히스토그램 신경망

11.1. Softmax를 사용하는 이유

신경망의 출력은

$$\hat{A}_i dr_i \geq 0$$

이고 합이 1이어야 한다.

$$\sum_i \hat{A}_i dr_i = 1$$

Softmax는 이 두 조건을 자동으로 만족시킨다.

이것은 단순한 ML 선택이 아니라 물리적 제약을 신경망 구조에 넣은 사례다.

11.2. 식 (6): Representative Size Error

논문은 일반적인 MSE 대신 다음 손실을 사용한다.

$$\boxed{\text{RSE} = \sum_i \left| \hat{A}_i - A_i \right| r_i \, dr_i} \tag{6}$$

여기서

- A_i: SP-WIFF가 만든 실제 i번째 bin
- $\hat{A}_i$: NN-WIFF 예측
- r_i: 해당 bin의 대표 floe 크기

이다.

오차에 r_i를 곱하기 때문에 큰 floe 구간의 오차를 더 중요하게 평가한다.

일반적인 bin별 MSE만 사용하면 작은 floe 구간이 많이 나뉘어 있을 때 작은 크기에서의 미세한 오차가 손실을 지배할 수 있다. RSE는 실제 관측 가능한 평균 floe 크기와 더 직접적으로 연결된다.

단위는 m이다.

11.3. 식 (7): 평균 학습성능

$$\boxed{P = \frac{1}{N}\sum_{j=1}^{N} \mathrm{RSE}_j \approx 30\ \mathrm{m}} \tag{7}$$

즉, 학습자료 전체에서 크기 가중 히스토그램 오차가 평균적으로 약 30 m라는 뜻이다.

그러나 30 m의 의미는 실제 평균 floe 크기에 따라 달라진다.

- 실제 floe가 30 m라면 매우 큰 오차
- 실제 floe가 500 m라면 상대적으로 작은 오차

그래서 정규화한 SSE를 추가한다.

11.4. 식 (8): Representative radius

$$\boxed{R = \sum_i r_i A_i dr_i} \tag{8}$$

이는 파단 히스토그램이 나타내는 대표 floe 크기 또는 평균 반경이다.

11.5. 식 (9): Standardized Size Error

$$\boxed{\mathrm{SSE} = \frac{\mathrm{RSE}}{R}} \tag{9}$$

예를 들어

$$R = 100\ \mathrm{m}, \qquad \mathrm{RSE} = 5\ \mathrm{m}$$

라면

$$\mathrm{SSE} = 0.05 = 5\%$$

이다.

검증자료 전체의 중앙값은

$$\boxed{\text{median SSE} = 3.9\%}$$

였다.

12. Figure 2 — 히스토그램 신경망의 전체 성능

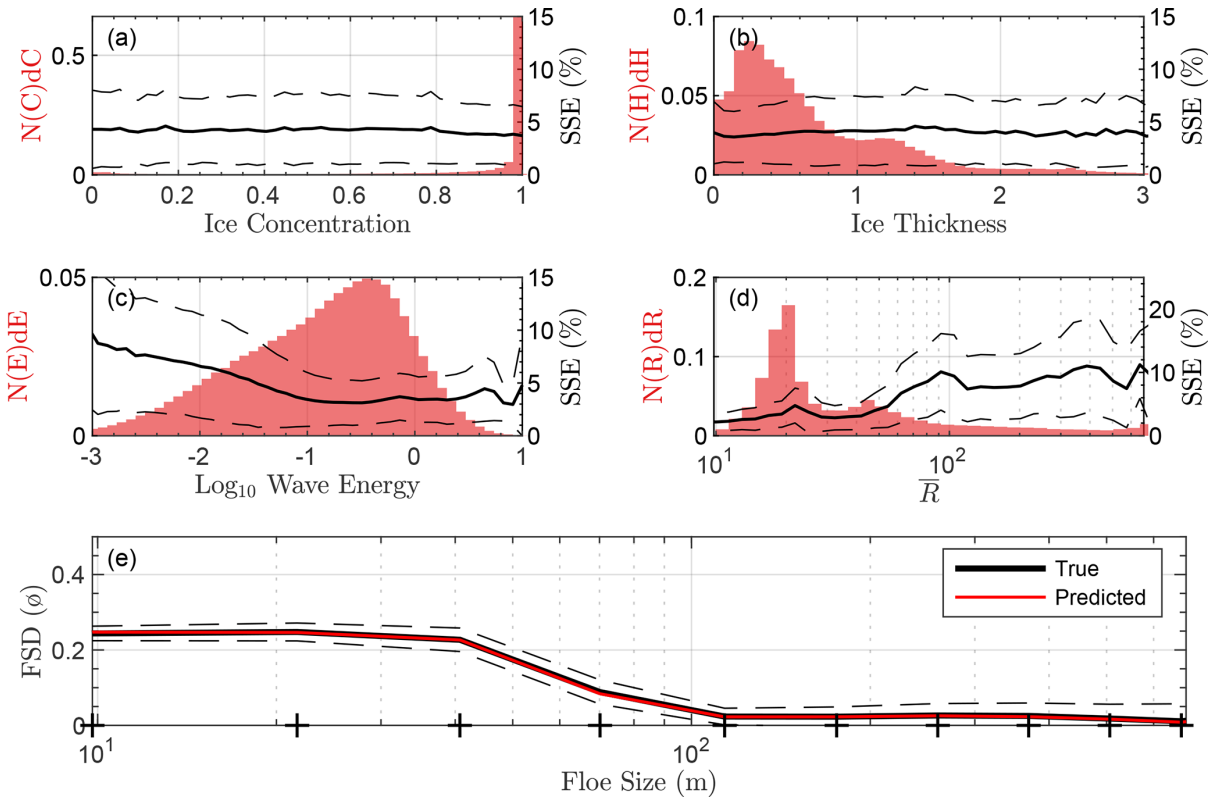


그림 7: 파단 히스토그램 신경망의 검증자료 성능. 원논문 Figure 2.

빨간 히스토그램은 검증자료가 어느 입력 영역에 많이 존재하는지를 보여준다.

검은 실선은 구간별 median SSE, 점선은 사분위 범위다.

12.1. (a) 해빙농도

농도에 따라 SSE가 거의 변하지 않고 대체로 5% 아래에 있다.

12.2. (b) 해빙두께

두께에 대해서도 median SSE는 대체로 5% 이하로 안정적이다.

12.3. (c) 파랑에너지

낮은 파랑에너지에서 오차가 상대적으로 크고, 에너지가 증가하면 감소하는 경향이 나타난다.

낮은 에너지에서는 파단 사례 수가 적고 파단 결과도 위상에 민감하기 때문이다.

12.4. (d) 실제 representative radius R

R이 커질수록 SSE와 불확실성이 증가한다.

큰 R은 작은 수의 파단만 발생했다는 뜻일 수 있다. 이 경우 무작위 파랑 위상에 따라 결과가 크게 변해 SP-WIFF 자체의 stochastic variability도 커진다.

12.5. (e) 실제·예측 평균 히스토그램

- 검은색: SP-WIFF
- 빨간색: NN-WIFF
- 십자가: 12개 floe-size bin 중심

두 선이 거의 겹친다.

각 구간의 median error는 6.2% 미만이고, 12개 구간 평균은 약 3.3%이다.

다만 이것은 평균 히스토그램이 유사하다는 결과다. 개별 사건마다 정확하다는 뜻은 아니기 때문에 Figure 3의 조건별 오차를 추가로 봐야 한다.

13. Figure 3 — 어느 조건에서 오차가 커지는가?

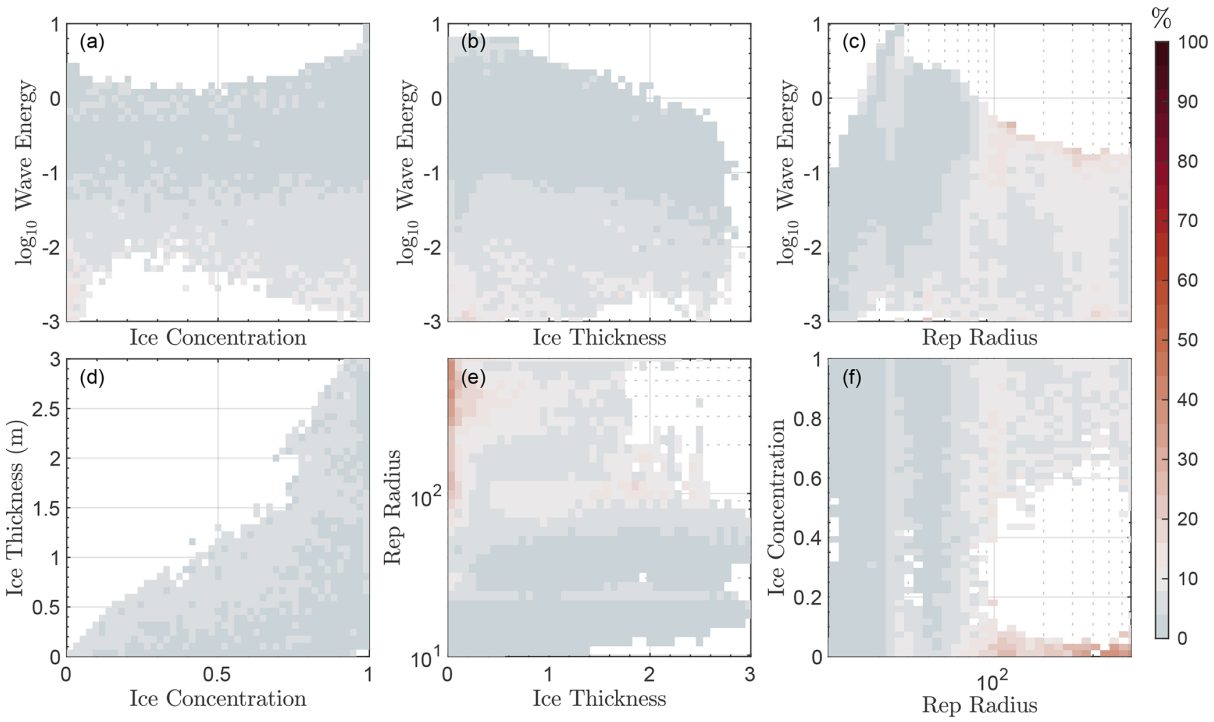


그림 8: 입력 조건에 따른 NN-WIFF의 median SSE. 원논문 Figure 3.

Figure 3은 입력변수 두 개의 조합에 따른 median SSE를 나타낸다.

전체적으로는 대부분의 영역에서

$$\text{SSE} \leq 5\%$$

이다.

하지만 다음 조건이 동시에 나타나면 오차가 커진다.

$$\boxed{\text{낮은 농도} + \text{얇은 얼음} + \text{낮은 파랑에너지} + \text{큰 } R}$$

이 영역에서는 실제 파단 사례가 적고, 파단이 일어나더라도 소수의 큰 floe를 남기는 불안정한 출력이 발생한다.

논문은 이 영역을 향후

- 별도의 모델로 처리하거나
- 입력에서 제외하거나
- 더 많은 자료를 생성하여 재학습하는 방법

을 고려할 수 있다고 설명한다.

참고로 Figure 3 설명문에는 panel (e)가 H–$\log E$ 조합으로 중복 기재되어 있지만, 실제 축을 보면 panel (e)는 얼음두께–representative radius 관계다.

프로젝트 연결

이 결과는 단순히 전체 RMSE 하나만 제시하면 안 되는 이유를 보여준다.
네 프로젝트에서도 오차를 다음 조건별로 나눠야 한다.

- 파랑이 약한 조건/강한 조건
- 얇은 얼음/두꺼운 얼음
- 낮은 농도/높은 농도
- 파단/비파단
- 관측이 많은 영역/희소한 영역
- 정상 범위/in-distribution과 OOD

특히 attenuation을 예측한다면 다음처럼 평가할 수 있다.

$$\hat{\alpha}(f) \quad \text{vs.} \quad \alpha_{\text{physics}}(f)$$

그리고 downstream 파랑 스펙트럼까지 계산해

$$\frac{\partial E(f)}{\partial x} = -\hat{\alpha}(f)E(f)$$

에서 얻은 H_s와 원래 물리모형의 H_s를 비교해야 한다.
즉,

$$\text{parameter error} \quad + \quad \text{downstream state error}$$

를 모두 평가하는 것이 좋다.

14. Section 4 — CICE 안에서의 실제 검증

이 절에서는 세 방법을 비교한다.

모형	의미
SP-WIFF	S1–S3을 수렴할 때까지 반복한 기준 물리모형
SP-WIFF$_1$	고정 위상으로 S1–S2를 한 번만 실행한 간이모형
NN-WIFF	두 신경망으로 SP-WIFF를 근사한 모형

14.1. 검증 설정

- CICE 6.1.4
- 약 1° 전지구 격자
- JRA-55 대기 재분석 forcing
- 2005년 1년 실행
- 학습자료는 2009년 자료

따라서 학습연도와 검증연도를 분리했다는 장점이 있다.

다만 중요한 제한이 있다.

2005년 검증에서는 CICE를 stand-alone으로 실행하고, 기존 CICE–WAVEWATCH III 실험에서 얻은 시간 변화 파랑 스펙트럼을 외부 forcing으로 제공했다.

따라서 학습자료는 fully coupled model에서 나왔지만, Section 4의 비교 실험 자체는 WAVEWATCH III와 CICE를 매 시간 온라인으로 상호 갱신하는 완전한 two-way coupled 검증은 아니다.

이는 네 프로젝트에서 one-way와 fully coupled 복잡도를 구분할 때 반드시 적어야 할 부분이다.

14.2. 호출 횟수 차이

1년 동안

항목	NN-WIFF	SP-WIFF/SP-WIFF$_1$
파단 발생 grid-point days	약 686,000	약 746,000
전체 WIFF 호출	약 1,230만	약 1,410만

NN-WIFF의 호출 횟수가 더 작은 이유는 분류기의 false negative 때문이다.

15. Figure 4 — CICE 내부에서의 파단분포 오차

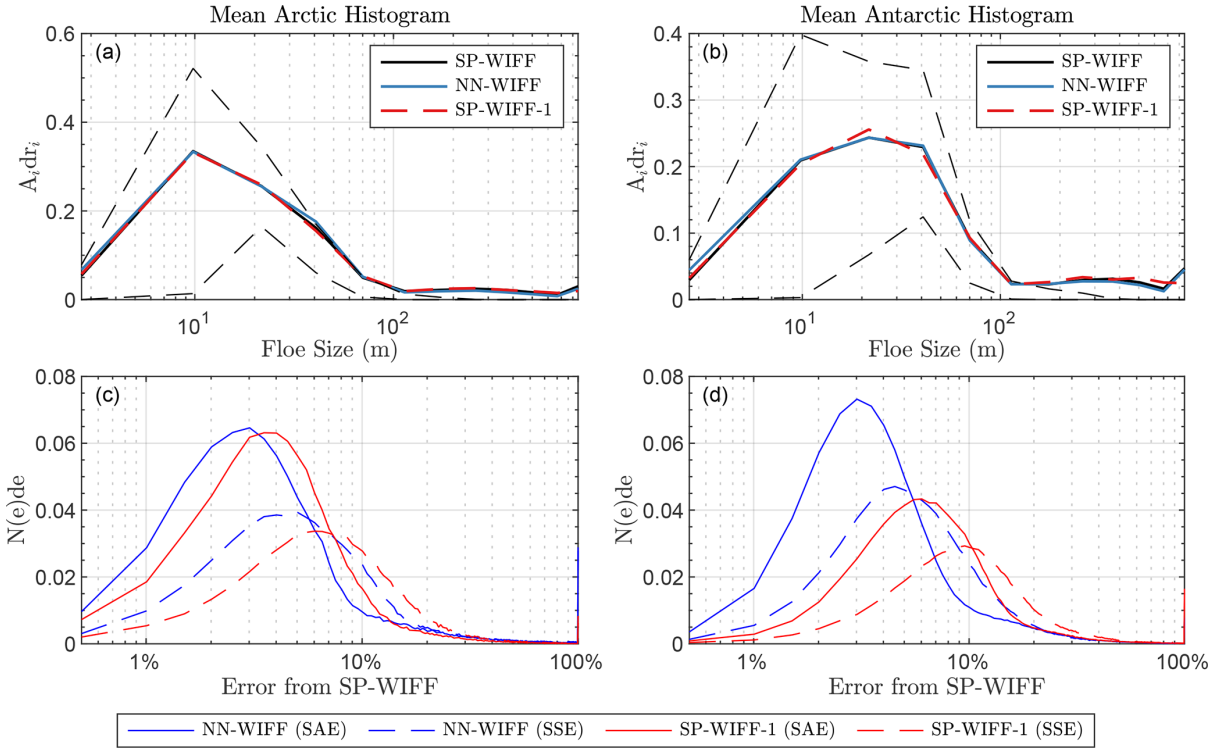


그림 9: 기후모형 내 WIFF 구현들의 오차 특성. 원논문 Figure 4.

15.1. 위쪽 (a), (b): 평균 파단 히스토그램

- 검은색: SP-WIFF
- 파란색: NN-WIFF
- 빨간 점선: SP-WIFF$_1$

북극과 남극 모두 세 모형의 평균 히스토그램이 거의 겹친다.

15.2. 아래쪽 (c), (d): SP-WIFF 대비 오차분포

- 실선: SAE, 구간별 absolute error의 합
- 점선: SSE

- 파란색: NN-WIFF
- 빨간색: SP-WIFF$_1$

결과는 다음과 같다.

지역	지표	NN-WIFF	SP-WIFF$_1$
북극	median SSE	8.9%	10.5%
북극	median SAE	5.8%	5.9%
남극	median SSE	8.1%	13.4%
남극	median SAE	5.52%	9.02%

즉, NN-WIFF는 계산이 훨씬 빠르면서도 한 번만 실행한 SP-WIFF$_1$보다 같거나 더 정확하다.

15.3. 중요한 조건부 비교 문제

Figure 4는 다음 경우만 포함한다.

- 세 방법 모두 파단을 발생시킨 위치
- 일평균 $E > 0.1\,\mathrm{m}^2$

따라서 이 그림은 "파단이 발생한다고 모두 동의한 조건에서 파단분포가 얼마나 비슷한가"를 보여준다.

반면 NN-WIFF가 파단 자체를 놓친 false negative 사례는 대부분 제외된다. 그러므로 Figure 4만으로 분류기와 히스토그램 네트워크의 전체 성능을 동시에 평가할 수는 없다.

16. Figure 5 — 모형 전체 해빙 상태에 미친 영향

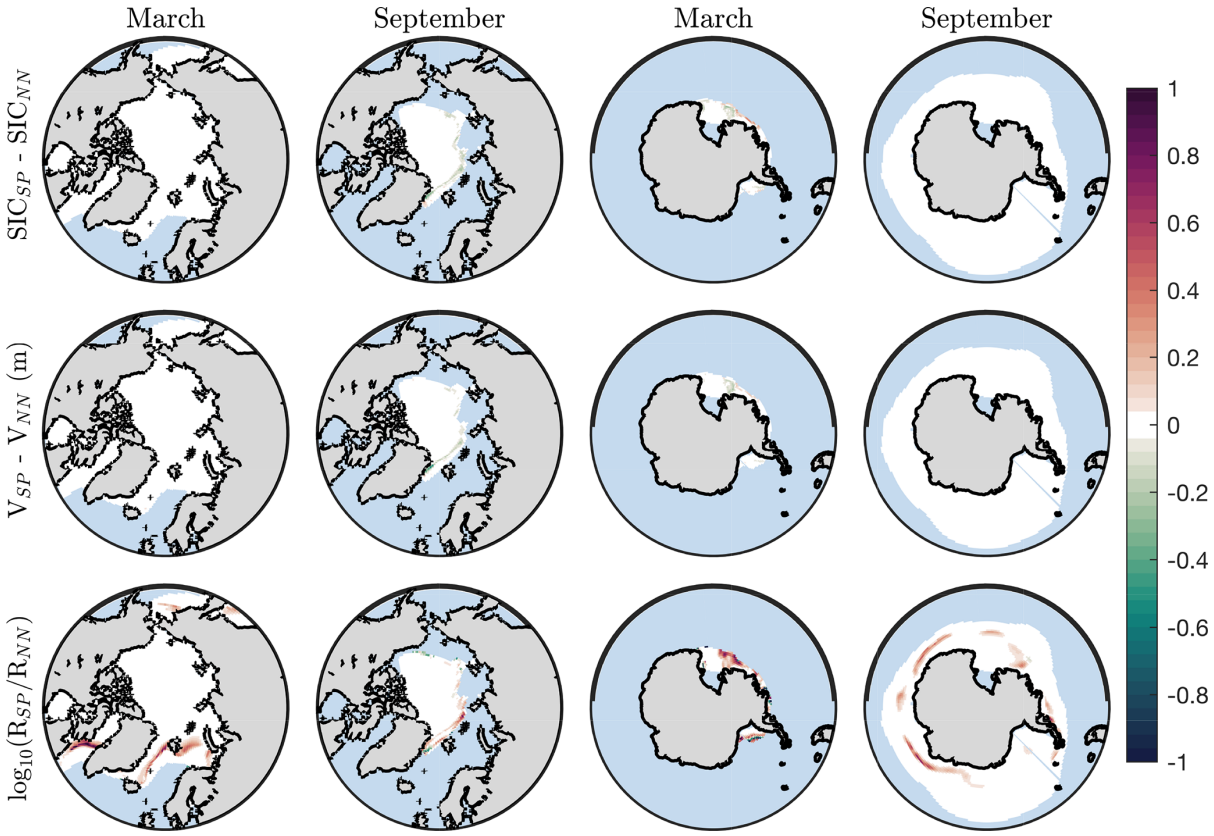


그림 10: SP-WIFF와 NN-WIFF가 계산한 전 지구 CICE 결과의 차이. 원논문 Figure 5.

열은 북극·남극의 3월과 9월이다.

16.1. 첫 번째 행: 해빙농도 차이

$$C_{\mathrm{SP}} - C_{\mathrm{NN}}$$

전반적으로 흰색에 가까우므로 두 모형의 농도 차이가 작다.

전 지구 해빙면적의 최대 차이는 1월 기준

$$47{,}000\ \mathrm{km}^2$$

이며 전체의 약 0.3%이다.

16.2. 두 번째 행: 단위면적당 해빙부피 차이

최대 전 지구 부피 차이는 1월 기준

$$33\ \mathrm{km}^3$$

이며 전체의 약 0.12%이다.

16.3. 세 번째 행: 평균 floe 크기 비율

$$\log_{10}\left(\frac{R_{\mathrm{SP}}}{R_{\mathrm{NN}}}\right)$$

을 나타낸다.

- 0: 두 모형의 representative radius가 동일
- 양수: SP-WIFF의 floe가 더 큼
- 음수: NN-WIFF의 floe가 더 큼

두 모형의 평균 floe 크기가 2배 이상 다르면

$$\left|\log_{10}\left(\frac{R_{\mathrm{NN}}}{R_{\mathrm{SP}}}\right)\right| > \log_{10}(2) \approx 0.3$$

이다.

이 차이는 주로 MIZ와 pack ice의 경계에서 나타난다. 이곳에서 SP-WIFF는 파단을 발생시켰지만 NN-WIFF 분류기가 파단을 놓쳤기 때문이다.

> 논문은 해당 면적을 4월에 1100 km^2, 전체 해빙면적의 4.8%라고 함께 적고 있는데, 두 수치는 규모상 잘 맞지 않는다. 따라서 이 값은 인용할 때 원문의 단위 또는 숫자 기재 오류 가능성을 표시하는 것이 안전하다.

16.4. "통계적으로 동일하다"의 정확한 의미

논문은 CICE의 two-stage paired thickness test를 적용해 SP-WIFF와 NN-WIFF의 결과가 "climate changing"하지 않다고 판단한다.

이는 다음을 뜻한다.

- 두 결과가 bitwise하게 같지는 않다.
- 지역별 floe 크기는 차이가 날 수 있다.
- 그러나 전 지구적 해빙면적·부피 변동은 통계적으로 구별하기 어렵다.

그렇다고 NN-WIFF 또는 SP-WIFF가 실제 자연을 정확히 재현했다는 의미는 아니다.

NN-WIFF가 teacher인 SP-WIFF를 잘 모방 ≠ 실제 자연에 대한 검증 완료

17. 계산시간 결과

모형 설정	1년 실행시간
CICE, FSD와 wave fracture 모두 없음	45분
CICE, FSD는 있지만 wave fracture 없음	56분
NN-WIFF	1시간 10분
SP-WIFF$_1$	3시간 30분
완전 수렴 SP-WIFF	약 24시간

SP-WIFF 대비 NN-WIFF의 속도 향상은

$$\frac{24\,\mathrm{h}}{1.167\,\mathrm{h}} \approx 20.6$$

배다.

전체 실행시간 감소율로 쓰면

$$1 - \frac{70}{1440} \approx 95.1\%$$

이다.

즉, 논문이 말하는 "95% 이상 계산비용 감소"가 여기서 나온다.

다만 FSD만 사용하는 CICE는 56분, NN-WIFF는 70분이므로 계산비용이 완전히 0인 것은 아니다. 정확하게는 SP-WIFF에 비해 추가 비용이 매우 작아졌다고 이해해야 한다.

프로젝트 연결

네 프로젝트에서도 속도는 신경망의 inference time만 재면 부족하다.
다음을 각각 측정해야 한다.

1. 기존 물리 routine 1회 실행시간
2. ML inference 1회 실행시간
3. 전체 시간 단계당 호출 횟수
4. 전체 numerical model wall-clock time
5. 자료 입출력 및 전처리 비용

최종적으로는

$$\text{Speedup} = \frac{T_{\text{physics}}}{T_{\text{ML}}}$$

뿐 아니라

$$\frac{T_{\text{full model, physics}}}{T_{\text{full model, ML}}}$$

도 보고해야 한다.

18. Section 5 — 결론과 한계

18.1. 논문의 최종 성과

- 510만 개 입력으로 학습
- 두 신경망으로 파단 여부와 분포를 분리
- 검증자료 median SSE 3.9%
- CICE 실행 중 median SSE 약 8.4%
- SP-WIFF 대비 실행시간 95% 이상 감소
- 전 지구적 해빙면적과 부피 통계는 유사
- 확률적 SP-WIFF보다 재현 가능한 계산 제공

18.2. 왜 offline 3.9%가 모델 내부에서 8.4%가 되었는가?

Offline 검증에서는 개별 입력에 대한 $\hat{A}$와 A를 비교한다.

하지만 CICE 안에서는

- 분류기의 false negative
- 반복 시간 적분
- FSD 변화의 누적
- 다음 단계 입력상태 변화
- 다른 열역학·역학 과정과의 상호작용

이 발생한다.

따라서 local surrogate error가 작아도 model-coupled error는 커질 수 있다.

이것이 네 프로젝트에서 반드시 기억해야 할 원칙이다.

$$\boxed{\text{Offline accuracy} \neq \text{Coupled-model accuracy}}$$

18.3. 단일 연도·단일 모형 자료의 문제

학습자료는 2009년 한 해의 단일 CICE–WAVEWATCH III 구성에서 얻었다.

따라서 다음 조건에서는 OOD 문제가 발생할 수 있다.

- 미래 기후에서 더 얇은 얼음
- 현재보다 강한 파랑
- 학습에 거의 없던 두께–농도 조합
- 다른 해빙모형 또는 wave model
- 다른 공간·시간 해상도
- 북극·남극이 아닌 Great Lakes

논문은 현재 자료가 충분히 넓은 상태공간을 포함한다고 가정하지만, 이것을 증명하지는 못한다.

18.4. 논문이 제안한 가장 좋은 향후 구조

논문은 OOD 입력이 들어오면 직접 SP-WIFF를 호출하는 hybrid fallback을 제안한다.

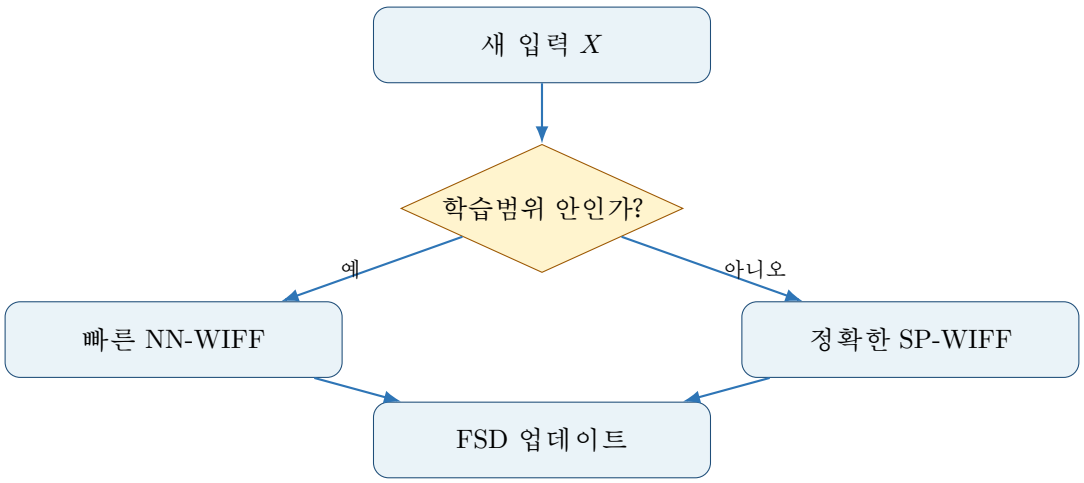


그림 11: OOD 입력을 처리하기 위한 hybrid fallback 구조

이를 수식으로 쓰면

$$\hat{A}(X) = \begin{cases} A_{\mathrm{NN}}(X), & X \in \mathcal{D}_{\mathrm{train}}, \\ A_{\mathrm{SP}}(X), & X \notin \mathcal{D}_{\mathrm{train}}. \end{cases}$$

이 방식은 네 프로젝트에도 매우 적합하다.

- 흔한 조건: ML surrogate 사용
- 희귀하거나 불확실한 조건: 기존 numerical model 사용
- 새로 계산된 결과를 학습자료에 추가하여 재학습

즉, active learning과도 연결할 수 있다.

18.5. 물리모형 자체의 가정

NN-WIFF가 아무리 정확해도 SP-WIFF의 가정을 그대로 상속한다.

SP-WIFF는 대략 다음을 가정한다.

- 얼음은 자유롭게 떠 있다.
- 얼음은 파면의 곡률에 즉시 반응한다.
- 1차원 10 km 영역의 변형률 통계가 격자 파단을 대표한다.
- SP-WIFF가 생성하는 파단 길이분포가 적절한 teacher다.

따라서 ML surrogate는 teacher보다 물리적으로 더 정확해질 수 없다.

$$\text{ML 성능의 상한} \approx \text{teacher model의 타당성}$$

19. Great Lakes 프로젝트에 직접 적용하면

네 Fall 2026 프로젝트의 목적은

- spectral wave model 및 wave–ice 문헌 검토
- wave attenuation 또는 ice fracture에 대한 NN surrogate 개발
- 기존 numerical model과 정확도 · 계산효율 비교
- 불확실성과 향후 연구방향 제시

이다.

이번 논문에서 그대로 가져올 수 있는 것과 그대로 가져오면 안 되는 것을 구분해야 한다.

19.1. 그대로 가져올 수 있는 것

19.1.1. 1. Teacher–surrogate 연구구조

$$X \xrightarrow{\text{기존 numerical model}} Y$$

$$X \xrightarrow{\text{NN}} \hat{Y}$$

19.1.2. 2. 두 단계 fracture 구조

$$P(\text{fracture} \mid X)$$

$$p(r \mid X, \text{fracture})$$

19.1.3. 3. 물리제약을 적용한 출력

FSD 또는 스펙트럼 분포를 예측한다면

- 음수 금지
- 합 또는 적분 보존
- 크기구간 순서 고려
- 에너지 또는 면적 보존

이 필요하다.

19.1.4. 4. 전체 모델 안에서의 검증

단순한 test MSE 외에

- 최종 H_s
- 파랑 침투거리
- 파단 여부
- 대표 floe 크기
- 전체 계산시간

을 비교해야 한다.

19.1.5. 5. OOD fallback

신경망이 불확실한 조건에서는 기존 물리모형을 실행하도록 만들 수 있다.

19.2. Great Lakes에 그대로 가져오면 안 되는 것

- 2009 CICE–WAVEWATCH III 학습자료
- 북극·남극에서 학습된 신경망 weight
- $H_s > 0.1$ m threshold
- $H < 10$ m와 $C > 0.01$ 조건
- 12개 floe-size bin
- sea-ice 물성에 맞춰진 파단 기준

Great Lakes의 담수빙은 해빙과 물성·계절성·공간조건이 다르고, 육지로 둘러싸인 호수이므로 파랑의 fetch와 경계조건도 다르다. 따라서 이전할 수 있는 것은 모델 구조와 검증 방법이지 학습된 함수 자체가 아니다.

20. 네 프로젝트에서는 논문보다 개선하면 좋은 부분

20.1. 무작위 70/30 분할 대신 blocked split

이 논문의 자료는 시공간적으로 연속된 격자–시간 자료인데 무작위로 70/30을 나눴다. 인접한 시점과 격자가 학습·검증에 함께 들어가면 검증성능이 낙관적으로 보일 수 있다.

네 프로젝트에서는 다음 중 하나가 더 좋다.

- 특정 겨울 또는 월을 test로 분리
- 특정 storm event를 통째로 test로 분리
- 특정 호수를 test로 분리
- 특정 공간영역을 test로 분리
- 극단적인 H_s, 얼음두께 조건을 OOD test로 분리

20.2. 평균오차 외에 물리적 결과 평가

예측문제	필요한 지표
파단 여부	recall, precision, FNR, FPR, confusion matrix
FSD 예측	RSE, SSE, 분포거리, 대표 floe 크기 오차
감쇠계수	주파수별 RMSE, bias, positivity violation
파랑 결과	H_s, T_p, 파랑에너지 감소율
coupled 결과	파랑 침투거리, ice edge, FSD 변화
계산효율	routine runtime, 전체 model runtime, speedup
일반화	계절·storm·호수별 성능, OOD 성능

20.3. 불확실성 제시

논문은 단일 예측 신경망에 가깝고 예측 불확실성을 직접 제공하지 않는다.

네 프로젝트에서는 복잡한 Bayesian NN까지 가지 않더라도 다음 정도는 가능하다.

- 여러 random seed로 모델 반복
- blocked split별 성능범위
- ensemble prediction
- 입력영역별 error map

- 학습자료 밀도와 오차의 관계
- OOD flag

이를 통해

$$\hat{Y}(X) \pm \text{uncertainty}$$

를 제시할 수 있다.

21. 이 논문에서 반드시 집중해서 읽을 부분

우선순위	부분	이유
1	Section 2, 식 (2)–(4)	NN이 대체하는 물리적 출력을 정의
2	Section 3의 27개 입력 · 12개 출력	프로젝트의 input–target 설계와 직접 연결
3	Section 3.1	파단/비파단의 2단계 구조
4	식 (6)–(9)	물리적으로 의미 있는 custom loss와 평가
5	Figures 2–3	평균성능이 아니라 오류 발생 영역을 분석하는 방법
6	Section 4의 세 모형 비교	baseline을 어떻게 구성할지 보여줌
7	계산시간 표	surrogate의 실제 필요성을 입증
8	Section 5의 OOD 논의	Great Lakes로 이전할 때 가장 중요한 한계

22. 최종 요약

1. SP-WIFF는 매 격자에서 무작위 파면을 생성하고 얼음 변형률과 파단 길이를 반복 계산하는 물리 기반 superparameterization이다.
2. 이 과정은 계산비용이 매우 크고 확률적이어서 bitwise reproducibility가 없다.
3. NN-WIFF는 SP-WIFF 전체가 아니라 S1–S3의 파단 히스토그램 생성 부분만 대체한다.
4. 입력은 파랑 스펙트럼 25개, 얼음두께, 얼음농도의 총 27개다.
5. 출력은 파단 여부와 파단 발생 시 12개 크기구간의 확률분포다.
6. 파단이 없으면 영벡터이고 파단 시 분포의 합은 1이므로, 분류기와 히스토그램 신경망을 분리했다.
7. 검증자료에서 분류 정확도는 87.5%, 파단 히스토그램 median SSE는 3.9%였다.

8. CICE 내부에서는 median SSE가 약 8.4%로 증가했지만 전 지구 해빙면적과 부피 통계는 SP-WIFF와 구별하기 어려웠다.
9. 전체 실행시간은 약 24시간에서 1시간 10분으로 감소해 약 20배 빨라졌다.
10. 그러나 이것은 SP-WIFF를 잘 모방했다는 결과이지 실제 관측된 자연을 검증했다는 뜻은 아니다.
11. 단일 연도·단일 해빙모형에서 학습했으므로 Great Lakes에 weight와 threshold를 직접 적용할 수 없다.
12. 네 프로젝트에서 가장 가져갈 만한 것은

    물리모형으로 자료 생성 → ML surrogate → 물리제약
    → downstream 검증 → OOD 시 원래 모형 호출

    이라는 전체 연구설계다.

결국 이 논문은 네 프로젝트에 "신경망을 사용했다"는 예시보다 더 중요하다. 어떤 expensive physics routine을 ML이 대체하고, 어떤 입력과 출력을 사용하며, 어떻게 물리제약·모형 내부 성능·계산시간·OOD 위험까지 검증해야 하는지 보여주는 가장 직접적인 선행연구라고 보면 된다.