Geoscientific Model Development, 15, 803–814, 2022

https://doi.org/10.5194/gmd-15-803-2022

© 저자(들) 2022. 이 저작물은 Creative Commons Attribution 4.0 License에 따라 배포된다.

WIFF1.0: 파랑 유발 해빙 플로 파쇄의 혼합형 머신러닝 기반 매개변수화

Christopher Horvat[1], Lettie A. Roach[2,3]

[1]Institute at Brown for Environment and Society, Brown University, Providence, RI, USA
[2]Department of Atmospheric Sciences, University of Washington, Seattle, WA, USA
[3]NASA Goddard Institute for Space Studies and Center for Climate Systems Research, Columbia University, New York, NY, USA

교신저자: Christopher Horvat (horvat@brown.edu)

투고: 2021년 8월 9일 – 토론 시작: 2021년 8월 25일
수정: 2021년 12월 20일 – 게재 승인: 2021년 12월 22일 – 출판: 2022년 1월 28일

논문 전체 한글 번역본

원문의 절 구성, 문단, 수식, 그림 설명, 공개문 및 참고문헌을 생략 없이 옮김

European Geosciences Union을 대표하여 Copernicus Publications가 출판함.

초록

해양 표면파는 크기가 서로 다른 해빙 플로(floe, 개별 빙편)들로 이루어진 불균질한 영역인 한계빙역(marginal ice zone)을 유지하는 데 중요한 역할을 한다. 한계빙역의 위치, 폭 및 발달은 해양 파랑과 플로 사이의 상호작용으로 결정되는데, 파랑은 해빙 내부로 전파되면서 해빙을 굽히고 파쇄한다. 이전 연구에서 우리는 확률적인 해양 표면파장과 해빙의 상호작용을 모의하기 위한 1차원 "슈퍼매개변수화(superparameterized)" 방안을 개발하였다. 이 방법은 계산 비용이 많이 들고 비트 단위로 재현되지 않으므로, 본 연구에서는 두 개의 신경망을 이용해 이 매개변수화를 가속함으로써 확률적 파랑–해빙 상호작용을 모의하는 데 적용 가능하고, 계산 비용이 낮으며, 재현 가능한 접근법을 제시한다. 이 가속화 코드를 해빙 모델 CICE에 구현한 결과, 계산 오버헤드를 늘리지 않으면서 전체 파랑 파쇄 코드가 산출하는 전 지구 통계를 재현하였다. 결합 모델인 Wave-Induced Floe Fracture(WIFF v1.0)는 공개되어 있으며, 파랑에 의한 해빙 파쇄 효과를 표현하려는 기후모델에 통합할 수 있다.

1 서론

해빙은 플로라고 불리는 개별 조각들의 집합체이다. 플로는 수평 기하학적 길이 척도(크기)가 수 미터에서 수십 킬로미터에 이르는, 서로 분리된 고체 해빙 조각이다. 그러나 기후모델 모의에서 해빙은 연속장으로 취급된다(Hibler, 1979; Golden et al., 2020). 기후모델에서 해빙 플로 기하구조 변화의 효과를 표현하기 위해, 여러 모델링 센터는 해빙 플로 크기 분포(floe size distribution, FSD)의 예측형 아격자 규모 매개변수화를 모델 물리의 핵심 요소로 포함하기 시작하였다(Horvat and Tziperman, 2015; Zhang et al., 2015; Roach et al., 2018b; Boutin et al., 2018; Bateson et al., 2020; Hunke et al., 2019). FSD는 확률분포 $f(r)$이며, 여기서 $f(r)\,dr$은 크기가 r과 $r + dr$ 사이인 플로로 구성된 격자 면적의 비율이다. 모든 양의 r에 대해 $f(r)$을 적분한 값은 해빙 농도 c와 같다.

아격자 규모 FSD를 모의하는 주요 장점 중 하나는 해빙 플로와 해양 표면파 사이의 결합 상호작용을 표현할 수 있다는 것이다. 해양 표면파는 한계빙역(MIZ; Wadhams et al., 1988; Langhorne et al., 1998; Squire et al., 1995)으로 알려진 영역에서 해빙 안으로 전파되고, 감쇠되며, 해빙을 파쇄한다. 파랑의 영향을 받는 해빙 피복 영역은 양반구에서 수백만 제곱킬로미터 규모인 것으로 관측되며, 계절과 반구에 따라 전체 해빙 피복의 최대 절반에 영향을 미친다(Horvat et al., 2020). 파랑이 해빙으로 전파되어 이를 파쇄할 때 해빙 농도나 두께가 직접 변하지는 않는다. 대신 이 파쇄 과정은 해빙 플로 크기를 변화시켜 외부 열역학적 또는 역학적 강제력에 대한 해빙의 민감도를 높이고(Steele, 1992; Feltham et al., 2006; Horvat et al., 2016; Horvat and Tziperman, 2017), 해양 파랑 에너지의 감쇠를 변화시킨다(Perrie and Hu, 1996; Meylan et al., 2021). 따라서 해빙 손실과 파랑 활동 사이에는 다음과 같은 결합이 존재할 것으로 추정된다. 즉, 파랑이 해빙 내부로 전파되어 이를 파쇄하고, 그 결과 해빙이 녹으며, 파랑 전파가 더욱 강화된다(Kohout et al., 2011; Asplin et al., 2012, 2014). 파랑에 의한 플로 파쇄는 측면 융해가 가장 많이 일어나는 여름철에 플로 둘레 길이의 변화를 유발하는 지배적 과정이다(Roach et al., 2019).

기후모델에서 결합된 파랑–해빙 피드백은 두 가지 아격자 규모 분포, 즉 FSD인 $f(r)$과 해양 표면파 스펙트럼 $S(\lambda)$에 관련된다. 여기서 λ는 파장이며, $\int S(\lambda)\,d\lambda = E(\mathrm{m}^2$ 단위)는 단위 제곱미터당 파랑 에너지이고, 유의파고 H_s에 대해 원문에는 $E = 4\sqrt{H_s}$로 제시되어 있다(Michel, 1968). 해양 표면파장의 벌크 특성을 FSD와 연결하기 위한 경험적 매개변수화들이 개발되어 왔으며, 이들은 일반적으로 파쇄된 플로가 멱법칙 분포를 따른다고 가정한다(Williams et al., 2013; Zhang et al., 2015; Bateson et al., 2020). 그러나 멱법칙 FSD가 자연에서 관측되는지(Herman, 2013; Stern et al., 2018a, b; Horvat et al., 2019), 그리고 파랑 유발 플로 파쇄 과정에서 멱법칙 크기 분포가 생성되는지(Horvat et al., 2016; Herman et al., 2021)에 관해서는 서로 상충하는 증거가 존재한다.

$S(\lambda)$와 $f(r)$을 연결할 때의 한 가지 난점은 해빙의 반응이 2차원 해양 수면고 장에 의해 결정된다는

점이다. 이 수면고 장은 해양 파랑 스펙트럼이 가질 수 있는 여러 표현 가운데 하나인 확률적 표현이다. Horvat and Tziperman(2015)이 고안한 접근법은 모든 해빙 피복 격자 셀에 고해상도 1차원 해양 표면파장을 생성하고, 해빙이 받는 변형률, 파랑 에너지의 감쇠 및 그 결과 나타나는 해빙 파쇄 통계를 명시적으로 해석하는 것이었다. 이하에서 SP-WIFF라 부르는 이 방법은 결합 기후모델에서 구름 효과를 매개변수화하기 위해 사용되는 "슈퍼매개변수화"(SP) 접근법(Randall et al., 2003; Grabowski, 2004)이나 해양 심층대류를 위한 접근법(Campin et al., 2011)과 넓은 의미에서 유사하다. SP-WIFF는 해빙 모델 CICE의 한 구성요소로 포함되어 있고(Roach et al., 2018b; Hunke et al., 2019), 해양 표면파 모델과 결합된 바 있다(Roach et al., 2019). SP-WIFF를 실행하면 계산 비용이 크다. CICE에 포함한 경우에는 계산 시간이 1자릿수 배수만큼 증가한다(제4절 참조). SP-WIFF는 확률적이므로 비트 단위로 재현되지 않는다. 즉, 동일하게 초기화되고 동일한 강제력을 받는 두 SP-WIFF 모의는 기계 정밀도 수준까지 동일한 출력을 만들지 않는데, 이는 흔히 기후모델 개발에 필요한 특성이다.

파랑 유발 해빙 파쇄에 대해 계산 비용이 낮고, 유연하며, 비트 단위로 재현 가능한 아격자 규모 매개변수화를 제공하기 위해, 우리는 입력 분류와 해빙 파쇄를 담당하는 두 개의 신경망을 이용한 가속 파랑 유발 플로 파쇄 매개변수화(NN-WIFF)를 제시한다. 전체 코드인 WIFF1.0(Wave-Induced Floe Fracture)은 공개되어 있으며, SP-WIFF와 NN-WIFF뿐 아니라 지정된 오차 한계, 가변 입력/출력 변수 및 모델 구성에 맞추어 NN-WIFF를 재학습하거나 조정하기 위한 코드도 포함한다. 이 모델은 결합 CICE–WAVEWATCH III 모의에서 얻은 510만 개의 입력 및 출력 벡터를 이용해 학습되었다(제3절 참조). 학습 자료의 연도와 일치하지 않는 연도에 자유 실행 결합 모의로 구현했을 때, NN-WIFF는 SP-WIFF가 산출한 것과 통계적으로 유의하게 다르지 않은 전 지구 해빙 변동성을 산출하는 동시에 계산 오버헤드를 95% 이상 줄였다.

2 SP-WIFF: 슈퍼매개변수화된 파랑 파쇄 방안

해양 파랑에 의한 해빙 파쇄의 슈퍼매개변수화는 Horvat and Tziperman(2015)의 제2.3절에서 유도되었고, 그 통계적 성질은 Horvat and Tziperman(2017)의 제3.4절에서 조사되었다. 또한 Roach et al.(2018b)의 제2.4절에서는 오프라인 파랑–해빙 상호작용과 함께 해빙 모델에 구현되었으며, Roach et al.(2019)에서는 완전 결합 파랑–해빙 모델에 도입되었다. 여기서는 이를 요약한다.

해양 표면파의 에너지가 다음의 이산 단방향 파랑 스펙트럼으로 기술되는 기후모델 격자 셀에 해당하는 영역을 생각하자.

$$S(\lambda_i)\,d\lambda_i = \int_0^{2\pi} S(\lambda_i, \Theta)\,d\lambda_i\,d\Theta. \tag{1}$$

수평 크기가 r과 $r + dr$ 사이인 플로만 고려하면, 시간 구간 dt 동안 영역의 $f(r)\Omega(r,t)\,dr\,dt/\tau$에 해당하는 비율(무차원)이 해양 표면파에 의해 파쇄된다. 매개변수 τ는 플로 파쇄가 일어나는 미리 정해진 시간척도이다. Roach et al.(2018a)의 구현에서 τ는 각각 빠르게 전파되는 파랑과 면적이 작은 FSD 범주에 대한 CFL 조건을 만족시키도록 적응형 시간 적분 알고리즘으로 결정된다(더 자세한 내용은 Horvat and Tziperman, 2017, Appendix A 참조). 파쇄된 면적은 그 자체의 플로 크기 분포를 갖는다. 즉, $\Omega(r,t)\,dr\,dt$ 가운데 이제 크기가 s와 $s + ds$ 사이인 플로에 속하는 비율은 $F(r,s)\,ds$(무차원)이며, $\int_0^\infty F(r,s)\,ds = 1$이다. 일반적으로 해양 표면파에 의한 파쇄로 발생하는 크기 r인 플로 면적의 시간 변화율은 다음과 같다.

$$\frac{\partial f(r,t)}{\partial t} = \frac{1}{\tau}\left[-f(r,t)\Omega(r,t) + \int_r^\infty \Omega(s,t)f(s,t)F(s,r,t)\,ds\right]. \tag{2}$$

해석의 편의를 위해 식 (2)의 표기법은 Horvat and Tziperman(2015)의 대응하는 식 체계(그 논문의 식 19–22)와 다르다는 점에 유의하라. 식 (2)는 FSD 발달을 구성하는 하나의 경향항이며, FSD는 Horvat and Tziperman(2015)에 설명된 것처럼 여러 외부 강제력(예: 열역학적 성장과 융해, 이류)에 반응한다.

외부 강제항은 각 모델 시간 단계마다 계산되지만, FSD $f(r,t)$는 위에서 언급한 적응형 시간 적분 방안을 이용해 예측적으로 발달한다. 파랑–해빙 결합은 해빙 모델의 각 격자 시간 단계마다 수행되므로, FSD와 예를 들어 플로 크기 의존 파랑 감쇠 방안(Meylan et al., 2021) 사이의 피드백을 허용한다.

식 (2)의 첫째 항은 단위시간당 크기 범주 r에서의 플로 면적 손실이고, 둘째 항은 더 큰 플로가 파쇄됨으로써 크기 범주 r의 플로 면적이 증가하는 양이다. 적분 구간은 주어진 어떤 플로도 더 큰 플로로 파쇄될 수 없고 따라서 $s < r$이면 $F(s,r) = 0$이라는 사실을 반영한다. 식 (2)가 파쇄된 해빙에 대한 일반적인 경향 방정식이므로, SP-WIFF는 Ω와 F를 모두 나타내는 매개변수화를 뜻하며, 각 해빙 두께 범주에서 이 두 항은 다음과 같이 평가된다.

S1. 이산 1차원 파랑 스펙트럼 $S(\lambda)\,d\lambda$를 (임의로 선택한) 길이 10 km의 1차원 해빙 변형률장 $\eta(x)$으로 변환한다(Horvat and Tziperman, 2015의 식 19–22 참조).

S2. 플로를 파쇄할 수 있는 연속된 변형률 극값 사이의 거리를 찾아 파쇄 길이의 집합 $\{L\}$을 구한다. 이 값들을 확률분포 $A(r)$로 구간화하며, 여기서 $A(r)\,dr$은 길이가 r과 $r+dr$ 사이인 파쇄 길이들이 길이 가중 방식으로 차지하는 비율이다. 표기법을 단순화하기 위해 Horvat and Tziperman(2015)의 $r\,R(r)$을 여기서는 $A(r)$로 대체했음에 유의하라.

S3. 수렴할 때까지, 즉 연속적으로 갱신되는 $A(r)$ 값들 사이의 평균 절대차가 5×10^{-4}보다 작아질 때까지 S1–S2를 반복하여 $\{L\}$의 크기를 늘린다.

각 파랑장과 이에 대응하는 파쇄 길이 집합(단계 S1과 S2)은 서로 독립적으로, 즉 길이 10 km의 파쇄되지 않은 플로에서 수행된다. 다음으로 히스토그램 $A(r)\,dr$을 이용하여 Ω와 F를 계산한다. 먼저,

$$\Omega(r,t) = \int_0^r A(s,t)\,ds, \tag{3}$$

이며, $\Omega(r,t)\,dr$은 r보다 작은 모든 파쇄 길이가 길이 가중 방식으로 차지하는 비율과 같다. 플로가 수평으로 무작위 분포한다고 가정하면 이는 파쇄될 크기 r인 플로의 비율과도 같다. 그 결과 나타나는 플로 크기 분포는 히스토그램 자체로 결정된다.

$$F(r,s,t)\,ds = \begin{cases} \dfrac{A(s,t)\,ds}{\int_0^r A(l,t)\,dl} = \dfrac{A(s,t)\,ds}{\Omega(r,t)}, & r \geq s, \\ 0, & r < s. \end{cases} \tag{4}$$

식 (4)의 분모는 s에 대해 $F(r,s,t)$가 정규화되도록 보장하며, 따라서 $F(r,s,t)\,ds$는 크기 r인 파쇄된 플로에서 생성되는 플로 크기의 확률분포이다.

따라서 SP-WIFF에는 확률적 구성요소(S1)와 비용이 많이 드는 극값 탐색 및 히스토그램 생성 구성요소(S2)가 포함된다. 수렴할 때까지 필요한 단계의 수(S3)를 미리 알 수 없으므로 실행 시간은 불확실하다. 여기서 이 수렴은 정상상태 파쇄 분포로 수렴하는 확률적 히스토그램 생성 코드와 관련되며, 파랑에서 해빙으로 향하는 피드백과는 관련이 없다는 점에 유의하라. 이전에는 이러한 문제를 피하기 위해 단계 S1에서 위상을 고정하고 단계 S3를 한 번만 반복하는 방식으로 SP-WIFF를 CICE에 구현하였다. 이 단일 반복 구현을 SP-WIFF$_1$이라고 부른다. 이렇게 단순화했음에도 CICE 실행 시간은 파랑 파쇄가 없는 기준 추정치보다 약 4배 증가한다(제4절 참조). 우리는 SP-WIFF의 입출력 자료로 학습한 신경망으로 S1–S3를 대체하여 SP-WIFF의 성능을 개선하고자 하며, 이를 NN-WIFF라고 부른다.

3 결합 파랑–해빙 상호작용 매개변수화의 가속

NN-WIFF 코드는 전체 슈퍼매개변수화(SP-WIFF)를 그 통계를 재현하면서 계산 오버헤드는 줄이는 매개변수화로 대체한다. 이 코드는 Python Keras 딥러닝 라이브러리를 이용해 학습한 두 개의 완전연결 순전파 신경망으로 구성된다. 하나는 NN-WIFF를 실행할지를 판단하는 100노드 × 100노드 입력 분류 방안이고, 다른 하나는 파쇄 히스토그램을 생성하기 위한, 각각 100개 노드로 이루어진 5개 은닉층의 신경망이다. 저파랑 조건에서 SP-WIFF가 파쇄되지 않은 해빙을 자주 반환하고, 우리는 해빙이 파쇄될 때만 히스토그램 생성 신경망을 학습하고 실행하고자 하므로 분류기 층을 도입하였다. 최근 관측된 해빙 파괴의 보편적 임계값 거동(Voermans et al., 2020)은 향후 연구에서 이 분류 층을 해빙이 파쇄되는 시점을 나타내는 단순한 물리 기반 임계값으로 대체할 기회를 제공할 수 있다.

신경망 구조는 손실함수와 노드 및 층의 수를 변화시키는 메타학습 접근법으로 선택하였다(WIFF1.0 배포본에는 신경망 크기를 바꾸는 코드가 포함되어 있다). 학습은 탄력적 역전파 방법을 사용하는 "adam" 최적화 방안으로 수행한다. 각 은닉 뉴런에는 정류 선형 유닛(rectified linear unit, RELU) 활성함수를 사용하며, 두 경우 모두 마지막 출력층에는 softmax 활성화를 사용한다. 이는 각각 이진값(분류기의 경우)과 합이 1인 히스토그램(파쇄 히스토그램 신경망의 경우)을 구하기 때문이다.

SP-WIFF는 임의의 어떤 입력에 대해서도 실행할 수 있으므로 크기에 제한이 없는 학습 자료 세트를 생성할 수 있다. 본 연구에서는 결합된 파랑–해빙 모의의 단일 연도(2009년) 자료를 이용한다. 이 모의는 Roach et al.(2019)의 FSD-WAVEv2 모의와 같지만, 여기서는 S1–S2를 한 번만 적용하는 대신 완전히 수렴한 파랑 파쇄 매개변수화, 즉 SP-WIFF$_1$ 대신 SP-WIFF를 사용한다. 양반구에서 6시간 간격의 파랑 스펙트럼, 해빙 농도, 해빙 두께 및 파쇄 히스토그램을 취했으며, 그 결과 가능한 입력 벡터는 총 1억 8천만 개가 된다(대부분은 해빙이 없는 지점이다). 결합 파랑–해빙 모의는 해빙 플로 크기와 두께의 전체 분포를 포함하지만, 평균 플로 크기, 평균 플로 두께 및 해빙 농도만 파랑 모듈에 전달된다. 이 값들은 파랑 감쇠 계산에 필요하므로 우리는 이 매개변수들을 이용하여 NN-WIFF를 구축한다. 국지 해빙 두께가 10 m 미만이고, 해빙 농도가 0.01보다 크며, 유의파고 $H_s = 4\sqrt{E}$가 0.1 m보다 큰 위치만 포함함으로써 학습 자료를 가지치기한다. 이 임계값들은 여기서 배포하는 WIFF 버전에서 SP-WIFF를 실행하기 전에도 확인한다. 이는 비정상적인 해빙 조건이나 낮은 파랑 에너지의 영역에서 잘못된 파랑 파쇄 함수 호출이 발생하는 것을 없앤다. 전체 해빙 지점은 1,790만 개이며, 그 가운데 510만 개가 위 조건을 충족한다.

따라서 전체 학습 자료 세트는 25개의 스펙트럼 진폭, 1개의 해빙 두께 및 1개의 해빙 농도로 이루어진 $N = 510$만 개의 입력 벡터로 구성된다. 파랑 에너지와 해빙 상태가 가질 수 있는 범위라는 점에서, 이 벡터들이 SP-WIFF 코드에 들어갈 수 있는 잠재적 입력 위상공간을 포함한다고 가정한다. 이 입력 벡터들은 "참(true)" SP-WIFF 출력에서 얻은 출력 벡터 세트, 즉 510만 개의 12범주 플로 확률분포 $A_i\, dr_i$와 짝을 이룬다. 그중 260만 개는 0이 아니다(즉, SP-WIFF가 플로 파쇄를 일으킨다). 우리는 Roach et al.(2019)이 제시한 12범주 FSD를 사용하기로 선택했으나, 이는 다른 용도에 맞게 쉽게 바꿀 수 있다. WIFF1.0 배포본에는 다음을 수행하는 코드가 포함되어 있다("코드 및 자료 이용 가능성" 문단 참조).

- 지정된 입력 스펙트럼과 두께를 이용하여 사용자 정의 학습 자료 세트 정의
- 사용자 정의 출력 히스토그램 크기 정의(즉, 서로 다른 FSD 범주)
- 입력 분류 방안의 설계 및 학습
- 히스토그램 생성 방안의 설계 및 학습

또한 신경망 학습과 여기에 제시한 결과 생성에 사용한 자료도 제공한다("코드 및 자료 이용 가능성" 문단 참조). 우리는 학습 자료 세트의 12범주 플로 확률분포에 대해 SP-WIFF의 결합 모델 출력을 사용하였다. 이 자료는 오프라인에서도 생성할 수 있으며, 임의의 어떤 입력에 대해서도 출력 히스토그램을 생성하는 오프라인 코드 `SP_WIFF_Standalone.m`을 제공한다. 이 코드는 SP-WIFF의 코드와 비트 단위

까지 동일하다.

3.1 입력 분류

히스토그램 $A_i\,dr_i$는 합이 1인 수들의 집합이며, 우리가 가속하려는 매개변수화의 목표값이다. 이는 출력의 합이 1이므로 softmax 활성화 층을 사용하도록 동기를 부여한다. 그러나 SP-WIFF를 실행해도 해빙이 항상 파쇄되는 것은 아니며, 참 출력 히스토그램이 0으로만 이루어진 벡터일 수도 있다. 따라서 거짓 양성의 가능성을 줄이기 위해, NN-WIFF가 히스토그램을 생성할 때와 생성하지 않을 때를 판별하는 분류층이 필요하다. 앞에서 제시한 $H_s = 4\sqrt{E} = 0.1\,\mathrm{m}$의 파랑 에너지 절단값을 도입하면 잠재적 거짓 양성의 대부분을 제거할 수 있음을 확인했으므로, 이 절단값을 적용한 다음 분류 신경망을 실행한다.

분류기의 학습 자료는 대응하는 이진값(파쇄/비파쇄)이 붙은 510만 개의 입력 벡터이다. 이를 무작위로 70/30 비율로 나누어 학습 자료 세트(360만 개)와 검증 자료 세트(150만 개)를 만들었으며, 각 세트에서 파쇄로 이어지는 비율은 동일하게 51%이다. 입력 분류기는 입력 벡터 하나를 받아 $0 < \chi < 1$인 단일 값을 반환하고, $\chi < \chi_{\mathrm{crit}}$이면 NN-WIFF 방안을 실행한다. 분류 임계값 χ_{crit}은 검증 자료 세트에 대해 분류기를 평가했을 때 나타나는 오차 특성을 최적화하여 결정한다. 전체 오차율 ϵ을 다음과 같이 정의하여 이를 최적화한다.

$$\epsilon = \frac{\text{거짓 양성 수} + \text{거짓 음성 수}}{\text{전체 입력 벡터 수}}. \tag{5}$$

$\chi_{\mathrm{crit}} = 0.54$일 때 $\epsilon = 12.5\%$로 최소가 됨을 확인하였다. 이 오차율은 거짓 양성률 10.6%와 거짓 음성률 14.0%에 해당한다.

그림 1은 검증 자료 세트에 대해 평가한 분류기의 오차 특성을 보여준다. 그림 1a–c에서는 거짓 양성률(파란색)과 거짓 음성률(초록색)의 관계를 각각 해빙 농도(그림 1a), 해빙 두께(원문에는 그림 1a로 표기), $\log_{10} E$(그림 1c)의 함수로 나타낸다. 또한 실행률(검은색 점선), 즉 NN-WIFF가 실행되는 비율과 $1 - \epsilon$인 전체 정확도(검은색 실선)를 함께 표시한다. 향후 모델 및 과학적 발전과 관련하여 흥미로운 점은 파랑 에너지가 0.01에서 $0.1\,\mathrm{m}^2$ 사이(유의파고 약 70 cm)일 때 SP-WIFF 호출이 최댓값을 보인다는 것이다.

일반적으로 입력 분류기는 해빙 농도와 두께의 전 범위에서 높은 정확도를 보이며, 거짓 양성과 거짓 음성의 분포도 평탄하다. 가장 높은 파랑 에너지 범위에서는 정확도가 더 낮아지며, 이때 거짓 양성과 거짓 음성이 모두 20%보다 높다. 전체 정확도의 2차원 지도를 그림 1d($\log_{10} E$ 대 해빙 농도), 그림 1e(해빙 두께 대 해빙 농도), 그림 1f($\log_{10} E$ 대 해빙 두께)에 나타낸다. 위상공간의 일부 영역에서는 분류기 정확도가 42%까지 낮아진다. 분류기 정확도는 실행률이 가장 높은 영역, 즉 높은 해빙 농도와 두께 및 0.01에서 $0.1\,\mathrm{m}^2$ 사이의 파랑 에너지에서 높다. 아래에서 살펴보듯이 이러한 영역은 잠재적 입력 상태에서 가장 큰 비중을 차지하며, 12.5%의 분류 오차는 기후모델 출력에서 통계적으로 유의한 차이를 일으키지 않는다. 그럼에도 원하는 경우, 예를 들어 더 높은 파랑 에너지에 대해 입력 분류를 개선할 수 있으며 WIFF1.0에는 분류기를 재학습하는 코드가 포함되어 있다.

3.2 파쇄 히스토그램 생성을 위한 신경망

파쇄 히스토그램 신경망은 길이 27의 입력 벡터를 받아, 합이 1이고 히스토그램 $A_i\,dr_i$를 근사하는 벡터 $\hat{A}_i\,dr_i$를 출력한다. 따라서 이 입력 파랑과 해빙 통계가 입력 분류를 통과하면 해빙 플로가 파쇄된다. 성능을 평가하기 위해 다음과 같이 각 플로 크기 범주에서 예측 히스토그램과 실제 히스토그램 사이의 절대차에 해당 범주의 플로 크기를 가중하는 "대표 크기 오차(representative size error)"를 최소화하는 사용자 정의 손실함수를 사용한다.

$$\mathrm{RSE} = \sum_i \left|\hat{A}_i - A_i\right| r_i\,dr_i, \tag{6}$$

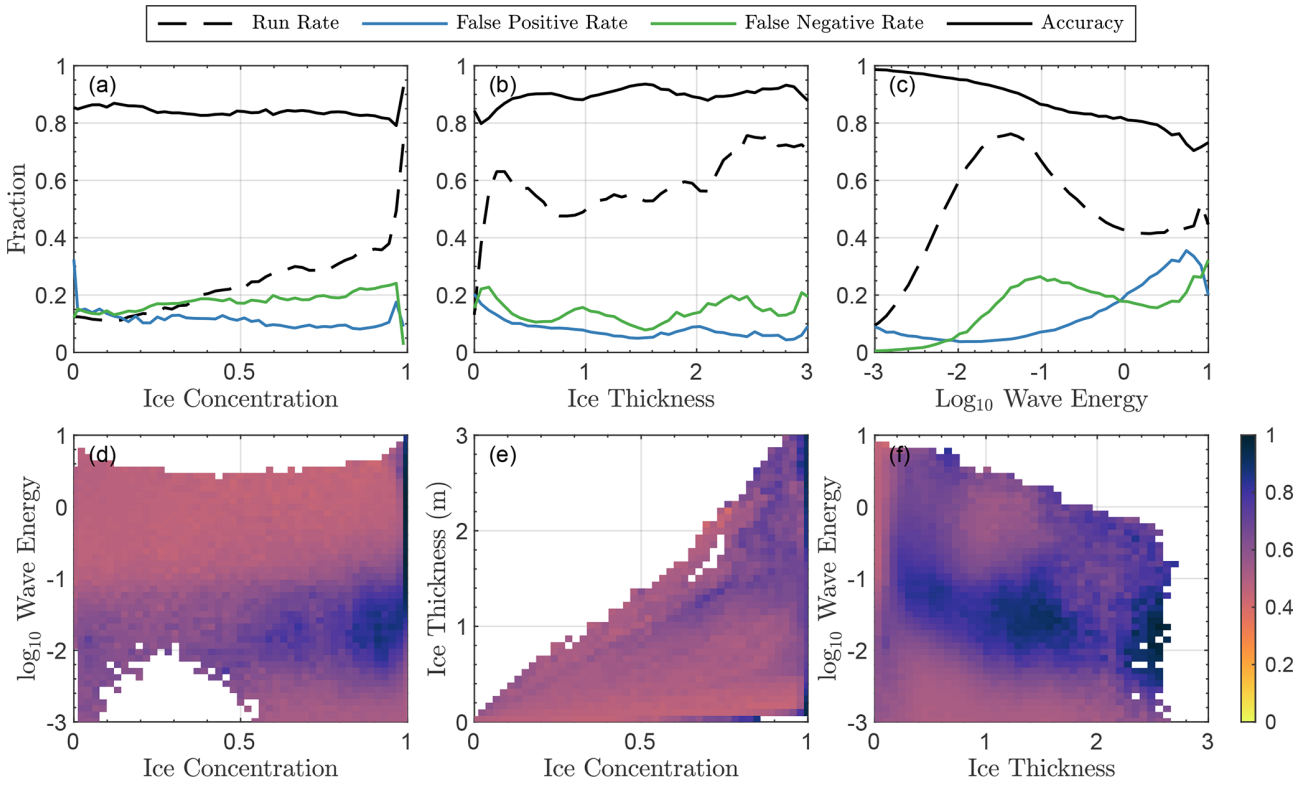


그림 1: NN-WIFF 입력 분류의 성능. (a) 해빙 농도의 함수로 나타낸, 분류기가 실행되는 비율(실행률, 검은색 점선), 히스토그램 신경망을 잘못 호출하는 비율(거짓 양성률, 파란색), 히스토그램 신경망을 호출하지 못하는 비율(거짓 음성률, 초록색) 및 입력 분류기의 전체 정확도(검은색). (b, c) (a)와 같지만 각각 (b) 해빙 두께와 (c) $\log_{10}$ 파랑 에너지에 대한 결과이다. (d–f) 각각 (d) 해빙 농도와 $\log_{10}$ 파랑 에너지, (e) 해빙 농도와 해빙 두께, (f) 해빙 두께와 $\log_{10}$ 파랑 에너지의 함수로 나타낸 평균 분류기 정확도의 히트맵. 입력 벡터가 75개 미만인 위상공간 영역(입력 자료의 0.005% 미만)은 색을 칠하지 않았거나 비어 있다.

이 값의 단위는 미터이다. 우리는 더 표준적인 척도(예: 제곱근평균제곱오차)보다 이 오차 통계량을 선택하였다. 평균 플로 크기는 관측 가능한 양(Horvat et al., 2020)이자 r의 양의 모멘트이므로, 작은 플로 크기에서의 오차나 플로 크기 이산화 변화에 덜 민감하기 때문이다. WIFF1.0 배포본에는 다른 표준 오차 척도를 이용해 신경망을 학습하는 코드도 제공한다. 이용 가능한 학습 자료는 입력 벡터의 70%로 이루어진 학습 자료 세트와 나머지 30%(~80만 개 입력 벡터)로 이루어진 검증 자료 세트로 무작위 분할한다. 이후 20단계 동안 검증 손실이 개선되지 않을 때까지 학습을 수행한다. 학습 자료를 j로 색인하면, 전체 신경망 성능은 학습 자료의 평균 오차이다.

$$P = \frac{1}{N}\sum_{j=1}^{N} \mathrm{RSE}_j \approx 30 \text{ m}, \tag{7}$$

여기서 N은 신경망 학습에 사용한 전체 입력 수이다.

그림 2에는 히스토그램 신경망의 종합 적합 특성을 제시한다. 그림 2a–d에는 검증 자료 세트의 해빙 농도 C, 해빙 두께 H, $\log_{10} E$ 및 "참" 대표 반지름 R의 개수 히스토그램(빨간색, 왼쪽 축)을 나타내며, R은 다음과 같다.

$$R = \sum_i r_i A_i \, dr_i, \tag{8}$$

이는 검증 자료 세트 입력으로부터 계산한다. 표준화한 신경망 오차를 평가하기 위해 다음과 같이 표준화 크기 오차(standardized size error, SSE)도 계산한다.

$$\mathrm{SSE} = \frac{\mathrm{RSE}}{R}, \tag{9}$$

이는 예상 평균 플로 크기로 오차에 가중치를 부여한다. 전체 검증 자료 세트에서 SSE의 중앙값은 3.9%이다.

SSE는 해빙 농도(그림 2a)나 해빙 두께(그림 2b)에 거의 의존하지 않는다. 고려한 모든 해빙 농도와 두께에서 SSE 중앙값은 5% 미만이며, 사분위 범위의 최댓값은 10% 미만이다. 파랑 에너지와 R 모두에 대한 중앙 오차 역시 모든 입력 파랑 에너지와 참 출력 플로 크기에서 10% 미만이지만, 낮은 파랑 에너지와 큰 R 값에서는 SSE가 더 크다. 소수의 잠재적 플로 파쇄만 있을 때 R이 크게 나타날 수 있는데, 이는 일반적으로 파랑 에너지가 낮아 해빙을 반복해서 파쇄하지 못할 때 발생한다. 일반적으로 신경망(그림 2e의 빨간색 선)은 각 플로 크기 범주에서 평균 파쇄 히스토그램 A_i(그림 2e의 검은색 선)를 정확하게 재현한다. $A_i \, dr_i$와 $\hat{A}_i \, dr_i$ 사이 오차의 중앙값은 모든 범주에서 6.2% 미만이며, 12개 범주 전체 평균은 3.3%이다.

어느 위상공간 영역에서 오차가 발생하는지 이해하기 위해 그림 3a–c에는 검증 자료 세트에 대해 평가한 SSE의 2차원 히트맵을 해빙 두께, 농도, R, 로그 파랑 에너지로 만들 수 있는 여섯 가지 조합 각각에 대해 표시한다. 자료의 적어도 0.005%(40개 지점)가 있는 좌표에만 색을 표시했고, 색상표의 흰색 지점은 오차 10%로 설정하였다. 파란색 값은 SSE < 10%인 경우이다.

그림 2는 가장 큰 오차를 갖는 입력 벡터가 입력 파랑 에너지는 낮고 그 결과 얻은 R은 큰 벡터임을 시사한다. 일반적으로 이 2차원 지도를 살펴보아도 유사한 결과를 얻는다. 대체로 입력 해빙 두께와 농도의 범위 전반에서 오차가 작다(SSE $\leq$ 5%, 그림 3a). 그러나 두께(그림 3b), 농도(그림 3f) 및 파랑 에너지(그림 3c)의 함수로 R에 대한 오차 지도를 확장해 보면, 학습 오차의 가장 큰 부분은 입력 해빙 농도가 낮고 두께가 얇으며 파랑 에너지가 낮은 영역에서 발생한다. 이 입력 조합은 큰 출력 R 값을 만들며, 이 값에서 SSE가 가장 크다. 해빙 농도가 낮은 위치는 WIFF 입력으로 사용하지 않지만, 현재로서는 해빙 두께가 얇은 위치를 제외하지 않는다. 이러한 영역에서 병리적인 출력이 나타난다는 사실은 향후 NN-WIFF 버전에서 이를 분리하거나 제외할 수 있음을 시사한다.

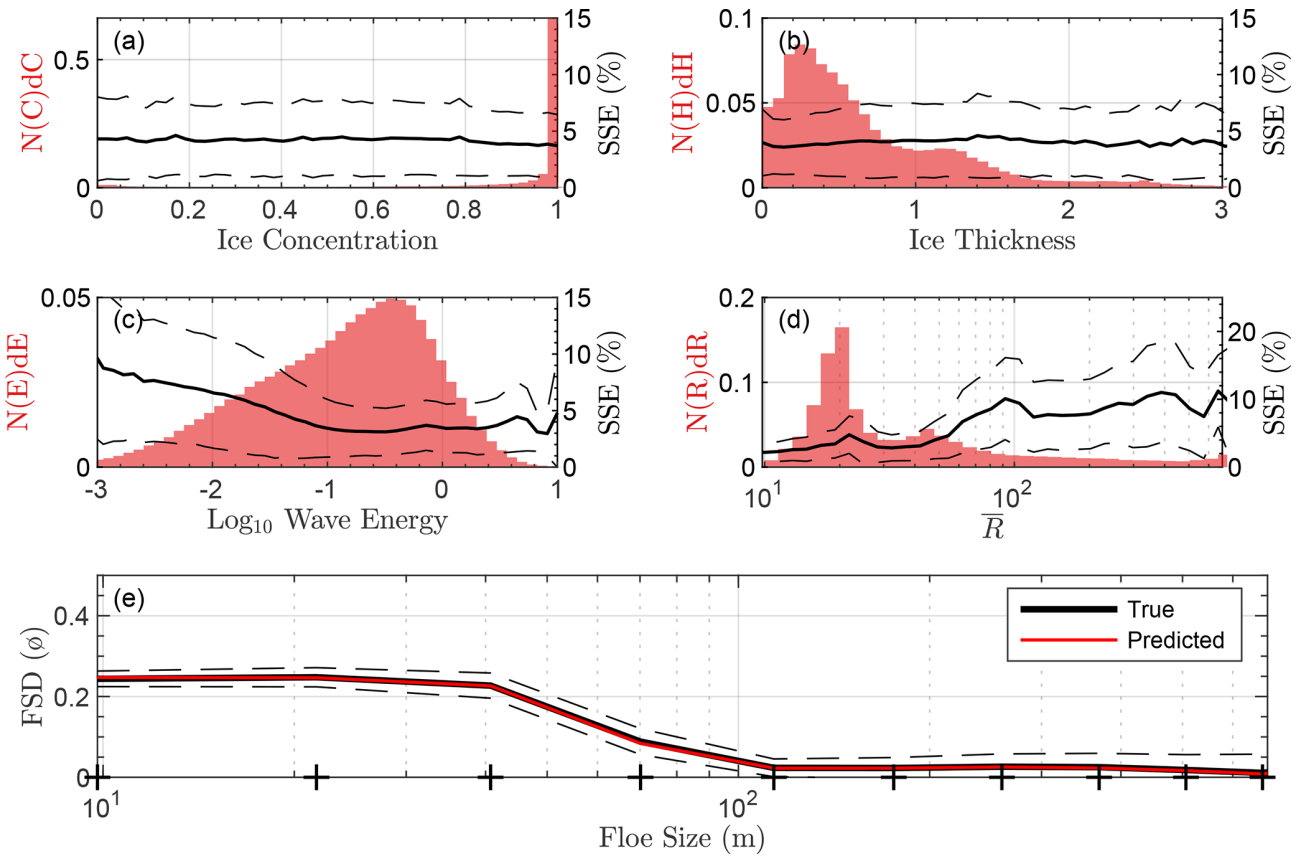


그림 2: 검증 자료에서 NN-WIFF의 성능. (a, 왼쪽 축) 검증 자료 세트에 포함된 해빙 농도 C의 히스토그램. (a, 오른쪽 축) C의 함수로 나타낸 표준화 크기 오차(SSE, 식 9)의 중앙값(실선). 점선은 SSE의 사분위 범위이다. (b–d) (a)와 같지만 각각 (b) 해빙 두께, (c) $\log_{10}$ 파랑 에너지, (d) "참" 출력 히스토그램의 대표 반지름(R, 식 8)에 대한 결과이다. (e) 검증 자료 세트(검은색)와 매개변수화 출력 $\hat{A}_i\, dr_i$(빨간색)의 평균 히스토그램 출력 $A_i\, dr_i$. 점선은 각 플로 크기 범주에서 $A_i\, dr_i$와 $\hat{A}_i\, dr_i$ 사이 오차의 표준편차이다. 십자 표시는 플로 크기 구간의 중심이다.

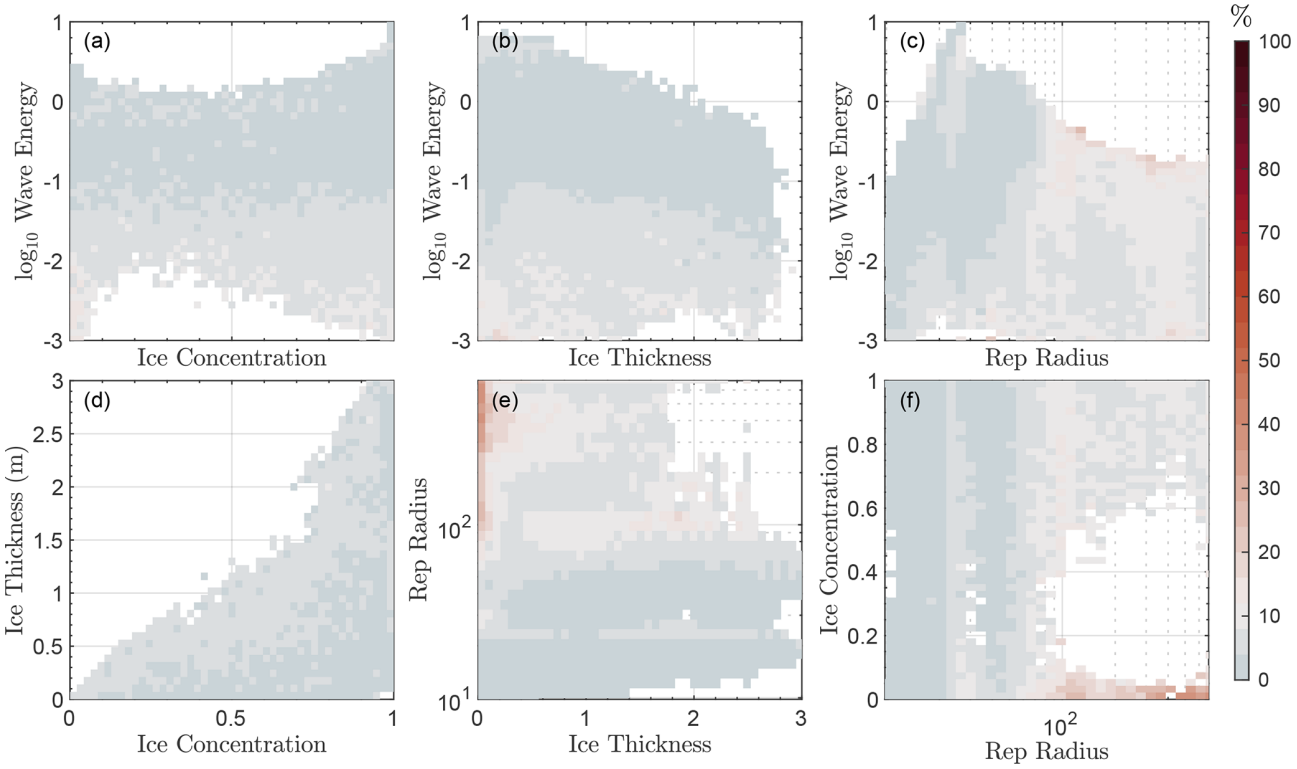


그림 3: NN-WIFF 학습 오차의 조사. (a) 검증 자료 세트에서 (가로축) 해빙 농도와 (세로축) $\log_{10} E$의 함수로 나타낸 SSE 중앙값의 2차원 지도. (b–f) (a)와 같지만 각각 (b) H와 $\log_{10} E$, (c) R과 $\log_{10} E$, (d) C와 H, (e) H와 $\log_{10} E$, (f) R과 C에 대한 결과이다. 자료의 0.005% 미만(~40개 지점)인 영역에는 색을 칠하지 않았다.

4 해빙 모델 결과

다음으로 자유 실행 해빙 모델에 WIFF 코드의 여러 버전을 구현했을 때 이들 사이의 관계를 조사한다. 여기서는 공칭 1° 공간해상도에서 JRA55 대기 재분석 자료(JRA-55 and Japan Meteorological Agency, 2013)로 강제한 독립 실행 모드의 전 지구 해빙 모델 CICE6.1.4(Hunke et al., 2019) 출력을 사용한다. 해빙 모델 강제력으로는 시간에 따라 변하는 해양 표면파 스펙트럼을 포함하며, 이는 Roach et al.(2019)이 기술한 CICE–WAVEWATCH III 결합 적분의 출력에서 가져왔다. 신경망 학습 입력으로 사용한 2009년 자료와 다른 경계조건 및 초기조건을 제공하기 위해 모델을 2005년 한 해에 대해 실행한다.

출력 히스토그램 $A_i\,dr_i$를 얻는 다음의 세 가지 방법에서 나온 결과를 조사한다.

1. **SP-WIFF**: 전체 SP-WIFF 모델과 제2절에서 설명한 수렴해를 사용한다.
2. **SP-WIFF**$_1$: SP-WIFF 모델을 사용하되, 위상을 고정한 상태에서 S1–S2 단계를 한 번만 반복한다.
3. **NN-WIFF**: 위에서 설명한 학습된 신경망을 사용한다.

CICE에서 출력되는 히스토그램 $A_i\,dr_i$는 24개의 1시간 시간 단계에 대한 일평균이다. 파랑 파쇄가 일어나지 않으면 $A_i\,dr_i$ 값을 0으로 설정한다. 따라서 파랑 파쇄가 일어날 때 $A_i\,dr_i$는 1로 정규화되지만, 평균을 계산하는 시간 단계 중 어느 한 단계에서 격자 셀이 항상 파쇄되지 않는다면 CICE 이력 출력은 1로 정규화되지 않는다. 우리는 히스토그램 출력의 합이 1이 되도록 재정규화하여 이러한 지점도 분석에 포함하기로 한다.

이 한 해 동안 NN-WIFF 모의에서는 NN-WIFF가 실행된 격자점–일(grid point day)이 686,000개이고, 전체 NN-WIFF 호출은 총 1,230만 회임을 확인하였다. SP-WIFF와 SP-WIFF$_1$에서는 이에 대응하는 값이 746,000개 및 1,410만 회이다. 함수 호출 수의 차이는 제3.1절에서 논의한 것처럼 거짓 음성을 도입하는 입력 분류기를 사용하기 때문에 생긴다.

그림 4a와 b에서는 그림 2e를 반복하되, 이제 세 방법 각각의 $A_i\,dr_i$ 값에 대한 (a) 북극 평균과 (b) 남극 평균을 살펴본다. 파쇄 차이를 추정하기 위해, 그림 4에는 세 모의 모두에서 WIFF가 해빙 파쇄를 일으키고 일평균 파랑 에너지가 $0.1\,\mathrm{m}^2$를 초과한 위치와 시각의 자료만 표시한다. 점선은 SP-WIFF 값의 사분위 범위를 나타낸다. 세 가지 구현에서 중앙값은 서로 유사하다.

그림 4a와 b를 만드는 데 사용한 것과 동일한 표본을 이용하여, 양반구에서 SP-WIFF와 SP-WIFF$_1$(빨간색) 사이 및 SP-WIFF와 NN-WIFF(파란색) 사이의 오차 히스토그램을 그림 4c–d에 나타낸다. 점선은 SSE, 실선은 각 범주의 절대오차 합(sum of absolute error, SAE)을 나타낸다. 두 척도와 양반구 모두에서 NN-WIFF는 실행될 때 SP-WIFF$_1$과 같거나 더 높은 정확도를 보이면서도 계산 비용은 크게 줄인다. 북극에서 SSE 중앙값은 8.9%(NN-WIFF)와 10.5%(SP-WIFF$_1$)이고, SAE 중앙값은 5.8%(NN-WIFF)와 5.9%(SP-WIFF$_1$)이다. 남극에서 SSE 중앙값은 8.1%(NN-WIFF)와 13.4%(SP-WIFF$_1$)이고, SAE 중앙값은 5.52%(NN-WIFF)와 9.02%(SP-WIFF$_1$)이다.

그림 5의 윗줄에는 각 반구의 3월과 9월에 대해 SP-WIFF와 NN-WIFF 사이의 월평균 해빙 농도 차이를 나타낸다. 두 모의 사이에는 차이가 거의 없으며, 1월의 전 지구 최대 면적 차이는 $47{,}000\,\mathrm{km}^2$(전체 해빙 면적의 0.3%)이다. 그림 5의 가운데 줄에서는 단위면적당 해빙 부피에 대해 이 분석을 반복한다. 다시 한 해 내내 차이가 거의 없으며, 1월의 전 지구 최대 부피 차이는 $33\,\mathrm{km}^3$(전체 해빙 부피의 0.12%)이다. 또한 그림 5의 아랫줄에서는 SP-WIFF와 NN-WIFF의 평균 플로 크기(대표 반지름) 비의 로그를 조사한다. 일부 영역에서는 SP-WIFF의 플로 크기가 NN-WIFF보다 크다. 평균 플로 크기의 차이가 2배 이상, 즉 $|\log_{10}(R_{\mathrm{NN}}/R_{\mathrm{SP}})| > \log_{10}(2) \approx 0.3$인 영역의 전 지구 최대 면적은 4월에 $1{,}100\,\mathrm{km}^2$, 즉 전체 해빙 면적의 4.8%이다. 이 영역들은 MIZ와 팩 아이스의 경계, 즉 NN-WIFF는 파랑 파쇄를 촉발하지 않지만 SP-WIFF는 촉발하는 위치에 나타난다. CICE 품질관리 검사(Roberts et al., 2018)를 이용하여 모델 적분 사이의 이러한 차이를 평가한다. 비트 단위 재현성은 없지만, 2단계 짝지은 두께 검정(two-stage paired thickness

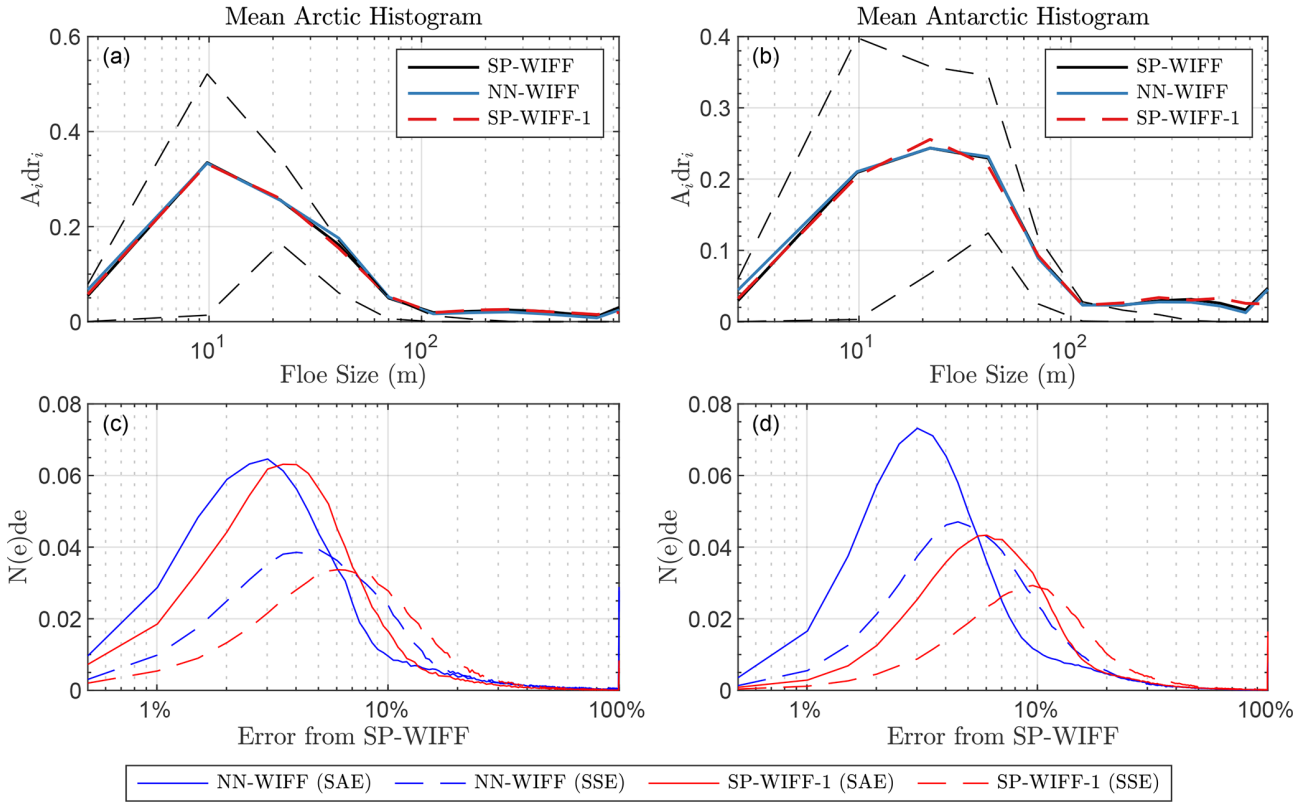


그림 4: 기후모델에서 WIFF의 오차 특성. (a) SP-WIFF(검은색), NN-WIFF(파란색), SP-WIFF$_1$(빨간색 점선)을 사용한 자유 실행 기후모의에서 북극의 평균 히스토그램 출력 $A_i\, dr_i$. 세 방법 모두 파랑 파쇄를 일으킨 경우에만 해당 지점을 히스토그램에 포함하였다. SP-WIFF 출력의 사분위 범위는 검은색 점선으로 나타낸다. (b) 남극에 대해 (a)와 동일하다. (c) 북극에서 SP-WIFF와 NN-WIFF(파란색) 또는 SP-WIFF$_1$(빨간색) 사이 오차의 히스토그램. 실선은 절대오차 합(SAE)이다. 점선은 표준화 크기 오차(SSE)이다. (d) 남극에 대해 (c)와 동일하다.

test)에 따르면 서로 다른 WIFF 구현은 “기후를 변화시키지” 않는 것으로 나타난다. 이는 파랑–해빙 상호작용이 해빙 상태에 미치는 영향(Roach et al., 2018b)에도 불구하고 WIFF 구현의 차이가 해빙 모델 상태에 창발적 효과를 일으키지 않음을 보여준다.

NN-WIFF는 파랑 유발 플로 파쇄의 매개변수화를 크게 가속한다. Cheyenne 슈퍼컴퓨터에서 매일 입출력을 수행하고 1개 노드와 24개 코어를 사용하여 384×320 전위극 격자(displaced pole grid)에서 이 모의들을 적분했을 때, 표준 SP-WIFF로 1년을 실행하는 데 약 24시간이 걸린다. 단일 반복 버전 SP-WIFF$_1$은 3시간 30분이 걸린다. NN-WIFF 모델은 1시간 10분이 걸린다. 비교를 위해, FSD는 있지만 파랑은 없는 표준 CICE 적분에는 56분이 걸리고, FSD와 파랑이 모두 없는 CICE 적분에는 45분이 걸린다. 여기서 이 실행 시간에는 파랑 모델의 적분 시간이 포함되지 않는다. 파랑 모델은 오프라인으로 실행되어 해빙 모델의 강제력으로 제공되었기 때문이다. 따라서 실행 시간은 컴퓨터 구조와 사용자가 지정한 컴파일러 설정에 따라 달라지겠지만, NN-WIFF는 파랑–해빙 파쇄 모의에 관련된 오버헤드를 크게 줄인다.

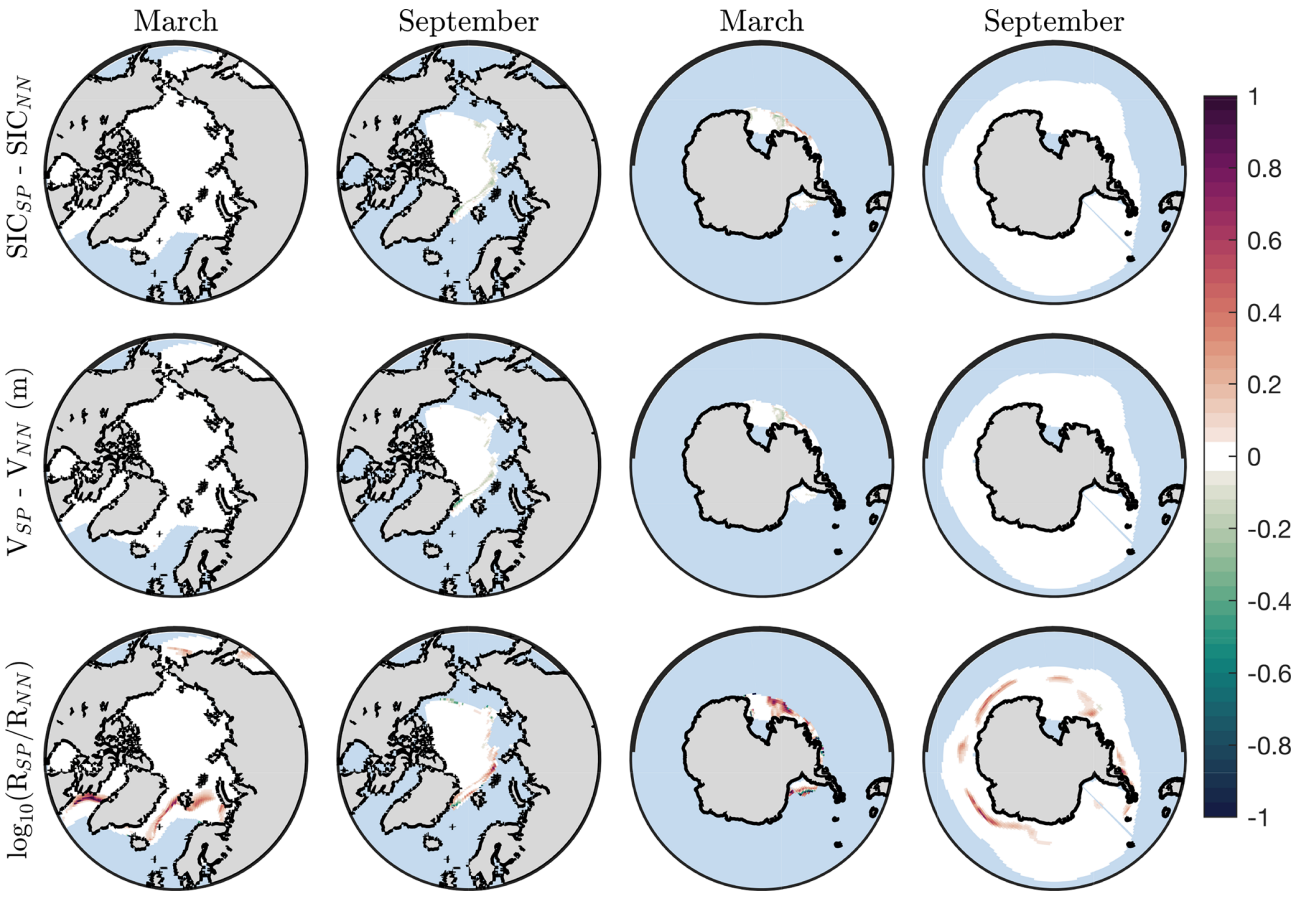


그림 5: 기후모델에서 WIFF의 구현. 각 반구에서 3월과 9월의 SP-WIFF와 NN-WIFF 사이 월평균 해빙 농도(SIC) 차이(윗줄). 가운데 줄은 해빙 부피 V에 대해 윗줄과 동일하다. 아랫줄은 대표 반지름 비의 $\log_{10}$에 대해 동일하다.

5 결론

여기서는 해양 표면파 모델과 결합된 해빙 모델에서 파랑 유발 플로 파쇄를 수행하는 코드인 WIFF1.0을 제시하였다. WIFF의 전체 "슈퍼매개변수화" 버전(SP-WIFF)은 활발한 파랑–해빙 상호작용이 일어나는, 파랑의 영향을 받은 한계빙역을 모의할 수 있지만 계산 비용이 많이 들기 때문에 장기간 기후 적분에 사용하기 어렵다. 대신 우리는 대규모의 실제 기후모델 입출력 쌍을 이용해 두 개의 신경망(NN-WIFF)을 학습하여 이 매개변수화를 가속하였다. 그 결과 80만 개 입력 상태로 이루어진 집합에 대해 평가했을 때 "표준화 크기 오차"의 중앙값은 3.9%이고, 자유 실행 기후모델 모의에서는 8.4%였다.

분류 층을 사용하기 때문에 NN-WIFF에는 거짓 양성과 거짓 음성이 생기며, 분류기 정확도는 87.5%이다. NN-WIFF 호출 여부를 정하는 에너지 임계값을 두었으므로 분류 신경망은 해빙 지점의 일부 축소된 집합에 대해서만 호출된다. 에너지 임계값은 전체 해빙 지점 중 약 72%에서 NN-WIFF의 잠재적 호출을 제거한다. 따라서 어떤 주어진 해빙 지점에서 NN-WIFF가 부적절하게 호출될 확률은 $0.125 \times 0.28 = 3.5\%$이고, NN-WIFF 호출의 "전체" 정확도는 96.5%이다. 계산상의 이유로 이전에 사용했던 SP-WIFF의 단일 반복 버전과 비교하면, NN-WIFF는 같거나 더 좋은 오차 특성을 보이면서 비용은 크게 낮다. 1년간의 기후모델 모의에서 NN-WIFF와 SP-WIFF의 전 지구 해빙 면적 및 부피 패턴은 통계적으로 구별할 수 없고, MIZ와 팩 아이스의 경계에서 대표 플로 크기만 약간 다르다.

신경망은 단일 모델의 현재 기후(2009년) 해빙 조건으로 학습되었으므로 파랑 스펙트럼과 해빙 두께의 위상공간이 달라지는 다른 기후에서는 성능이 낮을 수 있다. 모델 전망은 미래의 해빙 및 파랑 기후 상태가 현재와 상당히 달라질 것임을 보여주므로(예: Casas-Prat and Wang, 2020; Roach et al., 2020; SIMIP Community, 2020), NN-WIFF에 들어가는 전형적인 해빙 및 파랑 상태가 여기서 조사한 위상공간에서 벗어날 수 있으며 이는 문제를 일으킬 수 있다. NN-WIFF 학습에서는 해빙 및 파랑 조건의 지리적 · 시간적 변동성을 모두 표본화하는 폭넓은 모델 입력 벡터를 사용하였다. 입력 자료 세트가 단 한 해(2009년)에 걸쳐 있기는 하지만, 해빙 및 파랑 상태의 미래 궤적이 현재 모델 조건의 지리적 · 시간적 범위 안에 포함된다고 가정한다. 예를 들어 북극 해빙이 얇아지면 파랑의 영향을 받는 북극의 비율이 커질 수 있지만(Aksenov et al., 2017), 높은 파랑 상태와 얇은 해빙 사이의 상호작용은 현재 북극해 주변부와 남빙양에서 모의되고 있으므로 여기서 조사한 학습 자료의 위상공간 안에 포함된다.

그럼에도 향후 입력이 여기서 조사한 현재 조건의 일부로 표본화되지 않았을 가능성이 있다. 기존 NN-WIFF 버전은 다른 갱신된 기후모델 출력을 이용해 적응적으로 재학습함으로써 학습 자료 세트의 위상공간을 넓힐 수 있으며, WIFF1.0에는 임의의 파랑 및 해빙 입력 벡터에 대해 파쇄 히스토그램을 직접 생성하는 코드가 포함되어 있다. 예를 들어 Voermans et al.(2020)이 설명한 더 단순한 파괴 임계값을 포함하는 방식으로 NN-WIFF 모델의 입력 변수와 임계값을 조정하여 방법의 정확도를 높일 수도 있다. 향후 WIFF 버전에는 학습 위상공간 밖에 있는 입력 벡터를 표시하고 SP-WIFF를 직접 호출하여 이상치 입력을 더 잘 처리할 수 있는 혼합 기능을 구현하고자 한다. 여기서 고려한 CICE 모의가 생성하는 잠재적 해빙 농도, 두께 및 파랑 스펙트럼 상태의 위상공간은 이 변수들의 실제 위상공간이나 다른 기후모델 구성에서 모의되는 위상공간을 반영하지 않을 수 있다는 점에 유의한다. CICE–WAVEWATCH III 모의가 이 특정 잠재 입력 상태 집합을 대체로 재현한다고 가정하지만, 다른 모델링 시스템에 NN-WIFF를 구현하려면 더 넓거나 더 좁은 입력 조건 집합을 반영하도록 재학습해야 할 수 있다.

Horvat and Tziperman(2015)의 모델은 해빙이 파쇄되는 방식, 즉 해빙이 자유롭게 떠 있고 해양 수면고장의 곡률에 즉각 반응한다는 가정 아래 개발되었다. 최근 파랑 유발 파괴 관측의 발전은 해빙 플로 파쇄에 단일 임계값(Voermans et al., 2020)을 사용할 가능성을 제시하며, 이는 여기서 사용한 분류기 학습기를 대체하고 SP-WIFF의 플로 파쇄 표현을 개선할 수 있다. WIFF1.0 개발의 목적은 단순히 SP-WIFF를 근사 신경망 기반 코드로 대체하는 데 있다. 향후 WIFF 버전은 새로운 관측(예: Voermans et al., 2019)을 고려하여 개발하고, FSD와 파랑 모델 사이의 더 상세한 피드백을 포함할 수 있다. 파랑 모델과 해빙 모델 사이에서 전체 파랑 스펙트럼을 전달해야 한다는 요구는 일부 현세대 결합 방안에는 지나치게 부담스러울 수 있으며, 정확한 파쇄 히스토그램을 개발하는 데 더 적은 모델 매개변수만 필요할 가능성도 있다(예:

앞서 언급한 임계값). WIFF1.0 저장소에는 SP-WIFF를 독립 실행 방식으로 구동하고, 기후모델의 학습 자료를 취합하며, 신경망을 (재)학습하고, 이 논문에 사용된 그림을 생성하는 코드를 제공한다.

기후모델 출력에서 학습 자료를 쉽게 얻을 수 있기 때문에, 이러한 매개변수화 가속 접근법은 기후모델 모의의 다른 여러 측면에서도 유사하게 비용이 많이 드는 매개변수화, 특히 원시방정식의 해가 아닌 매개변수화에 활용되어 왔다(Rasp et al., 2018; Pal et al., 2019; Brenowitz et al., 2020). 이 접근법은 해빙 모델링에도 적용될 수 있다. 예를 들어 해빙 유변학 매개변수화는 일반적으로 지정된 허용오차까지 실행하는 복잡한 음해적 풀이법에 의존하지만, SP-WIFF와 마찬가지로 일련의 신경망 "블랙박스"로 분해할 수 있을지 모른다. 이 방법론은 WAVEWATCH III 코드에서 파랑–파랑 상호작용과 "원천" 항의 계산을 가속하는 데도 사용할 수 있다.

NN-WIFF를 개발한 주된 목표는 기존 SP-WIFF 매개변수화를 가속하는 방법을 제공하여 기후 규모 해빙 모델에 파랑–해빙 파쇄 매개변수화를 구현할 수 있게 하는 것이다. 일반적으로 NN-WIFF는 실행 시간을 유의하게 늘리지 않으면서 해빙 모델에 파랑–해빙 파쇄를 비용 효율적으로 구현할 수 있게 한다. 신경망은 기본 함수들의 단순한 집합이므로, 해양 표면파에 의한 해빙 파쇄를 모의하려는 어떤 기후모델에서도 손쉽게 사용할 수 있다.

코드 및 자료 이용 가능성

WIFF1.0 코드와 학습 자료 개발, NN-WIFF 구축 및 학습, Icepack과 CICE6에 구현하기 위한 코드는 https://doi.org/10.5281/zenodo.5793692에 공개되어 보관되어 있다(Horvat, 2021). WIFF의 지속적인 개발은 https://github.com/chhorvat/WIFF-Model에서 이루어진다(최종 접속일: 2022년 1월 25일). 모델 출력(2005년 강제력을 사용한 세 가지 WIFF 구성)과 학습 자료(2009년 SP-WIFF 모의)는 각각 Zenodo의 https://doi.org/10.5281/zenodo.5106703(Roach, 2021) 및 https://doi.org/10.5281/zenodo.5108636(Horvat and Roach, 2021)에서 이용할 수 있다. WIFF1.0 구현을 포함한 CICE6 및 Icepack 코드는 각각 https://github.com/lettie-roach/CICE/tree/mlwave와 https://github.com/lettie-roach/Icepack/tree/mlwave에서 활발히 개발되고 있다(최종 접속일: 2022년 1월 25일).

저자 기여

두 저자가 연구를 설계하였다. CH는 신경망을 학습하고 검증했으며 논문을 작성하였다. LAR은 NN-WIFF를 CICE에 통합하고 학습 및 검증을 위한 모델 실행을 수행하였다.

경쟁 이해관계

교신저자는 자신과 공동저자 모두 경쟁 이해관계가 없다고 선언하였다.

면책 조항

출판사 주: Copernicus Publications는 출판된 지도에서의 관할권 주장과 기관 소속에 대해 중립을 유지한다.

감사의 글

Christopher Horvat은 이 연구를 수행하는 동안 환대해 준 뉴질랜드 웰링턴의 National Institute of Water and Atmospheric Research에 감사한다.

연구비 지원

이 연구는 National Aeronautics and Space Administration(과제 번호 80NSSC20K0959), National Science Foundation, Directorate for Geosciences(과제 번호 OPP-1643431), 신흥 과학기술의 발전을 통해 사회적 성과를 개선하고자 하는 자선 이니셔티브인 Schmidt Futures, 그리고 Ministry of Business, Innovation and Employment(과제 번호 C01X1914)의 지원을 받았다.

심사문

이 논문은 Alexander Robel이 편집하였고 Timothy Williams와 Predrag Popovic이 심사하였다.

참고문헌

Aksenov, Y., Popova, E. E., Yool, A., Nurser, A. J., Williams, T. D., Bertino, L., and Bergh, J.: 북극 해상 항로의 미래 항행 가능성: 북극해와 해빙의 고해상도 전망, *Mar. Policy*, 75, 300–317, https://doi.org/10.1016/j.marpol.2015.12.027, 2017.

Asplin, M. G., Galley, R., Barber, D. G., and Prinsenberg, S.: 북극 폭풍의 결과로 해양 너울에 의해 발생한 여름철 다년빙의 파쇄, *J. Geophys. Res.-Oceans*, 117, 1–12, https://doi.org/10.1029/2011JC007221, 2012.

Asplin, M. G., Scharien, R., Else, B., Howell, S., Barber, D. G., Papakyriakou, T., and Prinsenberg, S.: 파쇄된 북극 다년빙 피복이 열역학적 · 역학적 해빙 과정에 미치는 영향, *J. Geophys. Res.-Oceans*, 119, 2327–2343, https://doi.org/10.1002/2013JC009557, 2014.

Bateson, A. W., Feltham, D. L., Schröder, D., Hosekova, L., Ridley, J. K., and Aksenov, Y.: 해빙 플로 크기 분포가 북극 해빙의 계절적 파편화와 융해에 미치는 영향, *The Cryosphere*, 14, 403–428, https://doi.org/10.5194/tc-14-403-2020, 2020.

Boutin, G., Ardhuin, F., Dumont, D., Sévigny, C., Girard-Ardhuin, F., and Accensi, M.: 파랑–해빙 상호작용에 대한 플로 크기의 효과: 가능한 영향, 파랑 모델에서의 구현 및 평가, *J. Geophys. Res.-Oceans*, 123, 4779–4805, https://doi.org/10.1029/2017JC013622, 2018.

Brenowitz, N. D., Beucler, T., Pritchard, M., and Bretherton, C. S.: 대류의 머신러닝 매개변수화 해석 및 안정화, *J. Atmos. Sci.*, 77, 4357–4375, https://doi.org/10.1175/JAS-D-20-0082.1, 2020.

Campin, J.-M., Hill, C., Jones, H., and Marshall, J.: 해양 모델링의 슈퍼매개변수화: 심층대류에의 적용, *Ocean Model.*, 36, 90–101, https://doi.org/10.1016/j.ocemod.2010.10.003, 2011.

Casas-Prat, M. and Wang, X. L.: 북극 극한 해양파의 전망과 연안 침수 및 침식에 대한 잠재적 영향, *J. Geophys. Res.-Oceans*, 125, e2019JC015745, https://doi.org/10.1029/2019JC015745, 2020.

Feltham, D. L., Untersteiner, N., Wettlaufer, J. S., and Worster, M. G.: 해빙은 머시층(mushy layer)이다, *Geophys. Res. Lett.*, 33, L14501, https://doi.org/10.1029/2006GL026290, 2006.

Golden, K. M., Bennetts, L. G., Cherkaev, E., Eisenman, I., Feltham, D., Horvat, C., Hunke, E., Jones, C., Perovich, D. K., Ponte-Castaneda, P., Strong, C., Sulsky, D., and Wells, A. J.: 해빙 모델링, *Not. Am. Math. Soc.*, 67, 1535–1555, https://doi.org/10.1090/noti2171, 2020.

Grabowski, W. W.: 슈퍼매개변수화를 위한 개선된 프레임워크, *J. Atmos. Sci.*, 61, 1940–1952, https://doi.org/10.1175/1520-0469(2004)061<1940:AIFFS>2.0.CO;2, 2004.

Herman, A.: 파편화된 해빙에서 힘 및 접촉 네트워크의 수치 모델링, *Ann. Glaciol.*, 54, 114–120, https://doi.org/10.3189/2013AoG62A055, 2013.

Herman, A., Wenta, M., and Cheng, S.: 파랑에 의해 파쇄된 해빙 플로의 크기와 형태 – 동남극 연안 사례 연구, *Front. Earth Sci.*, 9, 390, https://doi.org/10.3389/feart.2021.655977, 2021.

Hibler, W. D.: 동적 · 열역학적 해빙 모델, *J. Phys. Oceangr.*, 9, 815–846, https://doi.org/10.1175/1520-0485(1979)009<0815:ADTSIM>2.0.CO;2, 1979.

Horvat, C.: chhorvat/WIFF-Model: 릴리스 1.0 – CICE/ICEPACK 코드 포함(v1.0b), Zenodo [code], https://doi.org/10.5281/zenodo.5793692, 2021.

Horvat, C. and Roach, L.: NN-WIFF 학습 자료(Horvat and Roach, 2021), Zenodo [data set], https://doi.org/10.5281/zenodo.5108636, 2021.

Horvat, C. and Tziperman, E.: 해빙 플로 크기 및 두께 분포의 예측 모델, *The Cryosphere*, 9, 2119–2134, https://doi.org/10.5194/tc-9-2119-2015, 2015.

Horvat, C. and Tziperman, E.: 해빙 플로 크기 분포에서 척도 법칙의 발달, *J. Geophys. Res.-Oceans*, 122, 7630–7650, https://doi.org/10.1002/2016JC012573, 2017.

Horvat, C., Tziperman, E., and Campin, J.-M.: 해빙 플로 크기, 해양 소용돌이 및 해빙 융해의 상호작용, *Geophys. Res. Lett.*, 43, 8083–8090, https://doi.org/10.1002/2016GL069742, 2016.

Horvat, C., Roach, L. A., Tilling, R., Bitz, C. M., Fox-Kemper, B., Guider, C., Hill, K., Ridout, A., and Shepherd, A.: 위성 고도계를 이용한 해빙 플로 크기 분포 추정: 이론, 기후학 및 모델 비교, *The Cryosphere*, 13, 2869–2885, https://doi.org/10.5194/tc-13-2869-2019, 2019.

Horvat, C., Blanchard-Wrigglesworth, E., and Petty, A.: ICESat-2를 이용한 해빙 속 파랑 관측, *Geophys. Res. Lett.*, 47, e2020GL087629, https://doi.org/10.1029/2020GL087629, 2020.

Hunke, E., Allard, R., Bailey, D. A., Blain, P., Bouchat, A., Craig, T., Dupont, F., DuVivier, A., Grumbine, R., Hebert, D. A., Holland, M., Jeffery, N., Lemieux, J.-F., Rasmussen, T., Ribergaard, M., Roberts, A., Turner, M., and Winton, M.: CICE-Consortium/CICE: CICE 버전 6.0.2, Zenodo [code], https://doi.org/10.5281/zenodo.3516944, 2019.

JRA-55 and Japan Meteorological Agency: JRA-55: 일본 55년 재분석, 일별 3시간 및 6시간 자료, Research Data Archive at the National Center for Atmospheric Research, Computational and Information Systems Laboratory [data set], https://doi.org/10.5065/D6HH6H41, 2013.

Kohout, A. L., Meylan, M. H., and Plew, D. R.: 해빙 플로 바닥면의 거칠기로 인해 한계빙역에서 발생하는 파랑 감쇠, *Ann. Glaciol.*, 52, 118–122, https://doi.org/10.3189/172756411795931525, 2011.

Langhorne, P. J., Squire, V. A., Fox, C., and Haskell, T. G.: 해양 파랑에 의한 해빙의 파괴, *Ann. Glaciol.*, 27, 438–442, https://doi.org/10.3189/S0260305500017869, 1998.

Meylan, M. H., Horvat, C., Bitz, C. M., and Bennetts, L. G.: 해빙 플로에 의한 파랑 감쇠를 위한 2차원 및 3차원 플로 크기 의존 산란 모델, *Ocean Model.*, 161, 101779, https://doi.org/10.1016/j.ocemod.2021.101779, 2021.

Michel, W. H.: 단순화된 해양 스펙트럼, *Mar. Technol.*, 5, 17–30, 1968.

Pal, A., Mahajan, S., and Norman, M. R.: 슈퍼매개변수화된 E3SM 복사전달을 위한 비용 효율적 대리모델로서 심층 신경망의 활용, *Geophys. Res. Lett.*, 46, 6069–6079, https://doi.org/10.1029/2018GL081646, 2019.

Perrie, W. and Hu, Y.: 대기–해빙–해양 운동량 교환. 제1부: 파랑과 해빙 플로 사이의 에너지 전달, *J. Phys. Oceanogr.*, 26, 1705–1720, https://doi.org/10.1175/1520-0485(1996)026<1705:AMEPTB>2.0.CO;2, 1996.

Randall, D., Khairoutdinov, M., Arakawa, A., and Grabowski, W.: 구름 매개변수화의 교착상태 타개, *B. Am. Meteorol. Soc.*, 84, 1547–1564, https://doi.org/10.1175/BAMS-84-11-1547, 2003.

Rasp, S., Pritchard, M. S., and Gentine, P.: 기후모델의 아격자 과정을 표현하기 위한 딥러닝, *P. Natl. Acad. Sci. USA*, 115, 9684–9689, https://doi.org/10.1073/pnas.1810286115, 2018.

Roach, L.: 모델 출력: WIFF를 포함한 CICE6, Zenodo [data set], https://doi.org/10.5281/zenodo.5106703, 2021.

Roach, L. A., Dean, S. M., and Renwick, J. A.: 기후모델로 모의한 남극 해빙 농도의 일관된 편향, *The Cryosphere*, 12, 365–383, https://doi.org/10.5194/tc-12-365-2018, 2018a.

Roach, L. A., Horvat, C., Dean, S. M., and Bitz, C. M.: 전 지구 결합 해양–해빙 모델에서 창발하는 해빙 플로 크기 분포, *J. Geophys. Res.-Oceans*, 123, 4322–4337, https://doi.org/10.1029/2017JC013692, 2018b.

Roach, L. A., Bitz, C. M., Horvat, C., and Dean, S. M.: 해빙과 해양 표면파 사이 상호작용 모델링의 발전, *J. Adv. Model. Earth Sy.*, 11, 4167–4181, https://doi.org/10.1029/2019MS001836, 2019.

Roach, L. A., Doerr, J., Holmes, C. R., Massonnet, F., Blockley, E. W., Notz, D., Rackow, T., Raphael, M. N., O'Farrell, S., Bailey, D. A., and Bitz, C. M.: CMIP6의 남극 해빙 면적, *Geophys. Res. Lett.*, 47, e2019GL086729, https://doi.org/10.1029/2019gl086729, 2020.

Roberts, A. F., Hunke, E. C., Allard, R., Bailey, D. A., Craig, A. P., Lemieux, J.-F., and Turner, M. D.: 공동체 기반 해빙 모델 개발을 위한 품질관리, *Philos. T. R. Soc. Lond. A*, 376, 20170344, https://doi.org/10.1098/rsta.2017.0344, 2018.

SIMIP Community: CMIP6의 북극 해빙, *Geophys. Res. Lett.*, 47, 1–26, https://doi.org/10.1029/2019GL086749, 2020.

Squire, V. A., Dugan, J. P., Wadhams, P., Rottier, P. J., and Liu, a. K.: 해양 파랑과 해빙에 관하여, *Annu. Rev. Fluid Mech.*, 27, 115–168, https://doi.org/10.1146/annurev.fl.27.010195.000555, 1995.

Steele, M.: 단순한 해빙–해양 모델에서 해빙 융해와 플로 기하구조, *J. Geophys. Res.-Oceans*, 97, 17729–17738, https://doi.org/10.1029/92JC01755, 1992.

Stern, H. L., Schweiger, A. J., Stark, M., Zhang, J., Steele, M., and Hwang, B.: 보퍼트해와 축치해에서 해빙 플로 크기 분포의 계절적 발달, *Elementa*, 6, 48, https://doi.org/10.1525/elementa.304, 2018a.

Stern, H. L., Schweiger, A. J., Zhang, J., and Steele, M.: 해빙 플로 크기 분포에 관한 상이한 연구들의 조화, *Elementa*, 6, 49, https://doi.org/10.1525/elementa.304, 2018b.

Voermans, J. J., Babanin, A. V., Thomson, J., Smith, M. M., and Shen, H. H.: 해빙 난류에 의한 파랑 감쇠, *Geophys. Res. Lett.*, 46, 6796–6803, https://doi.org/10.1029/2019GL082945, 2019.

Voermans, J. J., Rabault, J., Filchuk, K., Ryzhov, I., Heil, P., Marchenko, A., Collins III, C. O., Dabboor, M., Sutherland, G., and Babanin, A. V.: 파랑 유발 해빙 파괴를 특징짓는 보편적 임계값에 대한 실험적 증거, *The Cryosphere*, 14, 4265–4278, https://doi.org/10.5194/tc-14-4265-2020, 2020.

Wadhams, P., Squire, V. a., Goodman, D. J., Cowan, A. M., and Moore, S. C.: 한계빙역에서 해양 파랑의 감쇠율, *J. Geophys. Res.*, 93, 6799, https://doi.org/10.1029/JC093iC06p06799, 1988.

Williams, T. D., Bennetts, L. G., Squire, V. A., Dumont, D., and Bertino, L.: 한계빙역의 파랑–해빙 상호작용. 제2부: 해수면의 1차원 횡단선을 따른 수치 구현 및 민감도 연구, *Ocean Modelling*, 71, 92–101, https://doi.org/10.1016/j.ocemod.2013.05.011, 2013.

Zhang, J., Schweiger, A., Steele, M., and Stern, H.: 한계빙역의 해빙 플로 크기 분포: 이론 및 수치 실험, *J. Geophys. Res.-Oceans*, 120, 3484–3498, https://doi.org/10.1002/2015JC010770, 2015.